

OUTLINE SKRIPSI NON KELAS/ARTIKEL ILMIAH

**PENERAPAN MODEL NLP UNTUK INTERPRETASI BERITA
CRYPTOCURRENCY DALAM MENINGKATKAN PEMAHAMAN INVESTOR
PEMULA**

**LEVERAGING NLP MODELS FOR CRYPTOCURRENCY NEWS
INTERPRETATION FOR IMPROVING BEGINNER INVESTOR INSIGHTS**

Topik: Artificial Intelligence

2702249556 ALEXANDER CHRISTIAN GANDASURYA COMPUTER SCIENCE /
+6281298986891

2702249650 FERNANDO ADDITTIYA COMPUTER SCIENCE / +6281392918440

2702274293 SAMUEL JEREMY WINOTO COMPUTER SCIENCE / +6281392235584



**Computer Science Program
Computer Science Study Program
School of Computer Science
Universitas Bina Nusantara
Jakarta
2026**

DAFTAR ISI

PENDAHULUAN.....	4
1.1 Latar Belakang.....	4
1.2 Rumusan Masalah.....	7
1.3 Ruang Lingkup.....	8
1.4 Tujuan dan Manfaat.....	9
1.5 Metodologi Penelitian.....	10
1.6 Sistematika Penulisan.....	15
TINJAUAN REFERENSI.....	17
2.1 Landasan Teori.....	17
2.1.1 Aset Kripto.....	17
2.1.2 Perilaku Investor Aset Kripto Pemula.....	18
2.1.3 Teori Sentimen Pasar.....	19
2.1.4 Natural Language Processing.....	20
2.1.5 Arsitektur Transformer.....	21
2.1.6 DeBERTa (Decoding-enhanced BERT with Disentangled Attention).....	22
2.1.7 Model FLAN T-5 (Fine-tuned Language Net).....	23
2.1.8 all-MiniLM-L6-v2.....	25
2.1.9 NER.....	26
2.1.10 Evaluasi Model.....	28
2.1.11 Data Flow Diagram.....	29
2.2 Related Works.....	29
2.2.1 Cryptocurrency Sentiment Analysis Using Deep Learning for Market Prediction (Kraaijeveld & De Smedt, 2020).....	29

2.2.2 Comparative Analysis of T5 Model Performance for Indonesian Abstractive Text Summarization (Satya et al., 2025).....	31
2.2.3 Multi-label Text Classification for Financial News Using DeBERTa (Timoneda & Vallejo Vera, 2024).....	32
METODE PENELITIAN.....	37
3.1 Kerangka Berpikir.....	37
3.2 Metode Penelitian.....	37
3.2.1 Pengumpulan Data.....	37
3.2.2 Pra-pemrosesan Teks (Text Preprocessing).....	37
3.2.3 Filter Aset Utama.....	38
3.2.4 Deteksi Kebaruan (Novelty Detection).....	38
3.2.5 Implementasi Inferensi AI (Analisis Mendalam).....	40
3.2.6 Penyimpanan Data dan Penyajian API (Data Serving & Backend).....	42
3.2.7 Visualisasi Antarmuka.....	43
3.2.8 Evaluasi.....	43
3.3 Perancangan Sistem.....	44
3.3.1 Data Flow / Context Diagram (Level 0).....	44
3.3.2 Data Flow Diagram (Level 1).....	45
3.3.3 User Interface Design.....	47
DAFTAR PUSTAKA.....	51

1. PENDAHULUAN

1.1. Latar Belakang

Perkembangan teknologi digital telah membawa dampak signifikan bagi pasar keuangan global, salah satunya pasar aset kripto yang telah menunjukkan perkembangan pesat dalam satu dekade terakhir. Menurut laporan Chainalysis (2023), populasi aset kripto global telah meningkat lebih dari 880% sejak tahun 2020, dengan pertumbuhan paling signifikan terjadi di negara-negara berkembang, termasuk Indonesia. Perkembangan ini berhasil menimbulkan kenaikan dalam populasi arus informasi dan berita.

Selain itu, kripto juga merupakan aset yang memiliki volatilitas harga tinggi. Sehingga kedua poin utama ini menimbulkan tantangan bagi banyak investor, terutama pemula yang kesulitan memahami dinamika pergerakan pasar kripto. Penelitian Corbet, S., et al. (2020-2021) menunjukkan bahwa pergerakan pasar aset kripto dipengaruhi oleh berbagai hal; faktor ekonomi, eksposur media, dan sentimen publik. Sehingga pemahaman terhadap berita-berita yang beredar merupakan bagian penting dari proses pengambilan keputusan dalam investasi aset kripto.

Tantangan utama yang dihadapi investor pemula adalah sifat pasar kripto yang beroperasi 24/7 dengan volatilitas ekstrem, yang sering memicu perilaku investasi impulsif. Fenomena FOMO (*Fear of Missing Out*) dan *Panic Selling* sering terjadi karena investor tidak mampu menyaring informasi secara objektif di tengah hiruk-pikuk berita global. Tanpa adanya alat bantu yang mampu memberikan interpretasi yang mudah dipahami, investor cenderung bereaksi hanya berdasarkan narasi permukaan tanpa memahami dampak fundamental yang sebenarnya dari sebuah peristiwa.

Dengan populasi investor aset kripto yang kini sudah berkembang pesat, terdapat berbagai aplikasi media seperti CoinMarketCap, CoinGecko, TradingView, dan aplikasi berita kripto seperti CoinTelegraph dan Decrypt yang menyediakan informasi pasar dan berita terkini. Namun, *platform-platform* tersebut memiliki kekurangan fitur sebagai berikut.

- Berita disajikan dalam format teks panjang yang teknis tanpa penyederhanaan, sehingga investor pemula sering mengalami *information overload* dan kesulitan dalam memahami poin-poin dari berita tersebut.

- Analisis sentimen yang diberikan seringkali subjektif (berbasis *voting*) dan tidak menyediakan klasifikasi multidimensi (seperti tingkat dampak dan target audiens).
- Tidak ada fitur *filter* kebaruan yang mengakibatkan pengguna mengonsumsi berita yang intinya sama secara berulang dari berbagai sumber berbeda.
- Minimnya identifikasi aset kripto secara otomatis di dalam teks berita, yang menyulitkan pengguna untuk memahami pengaruh berita terhadap aset spesifik dalam portofolio mereka.

Tantangan utama yang dihadapi investor pemula adalah sifat pasar kripto yang beroperasi 24/7 dengan volatilitas ekstrem, yang sering memicu perilaku investasi impulsif. Fenomena FOMO (*Fear of Missing Out*) dan Panic Selling sering terjadi karena investor tidak mampu menyaring informasi secara objektif di tengah hiruk-pikuk berita global. Tanpa adanya alat bantu yang mampu memberikan interpretasi yang mudah dipahami, investor cenderung bereaksi hanya berdasarkan narasi permukaan tanpa memahami dampak fundamental yang sebenarnya dari sebuah peristiwa.

Merva *et al.* (2022) mengidentifikasi bahwa investor kripto dengan pengetahuan keuangan rendah cenderung mengambil keputusan finansial yang impulsif karena tidak memahami konteks berita dan risiko. Hal tersebut merupakan salah satu bukti bahwa adanya kesenjangan nyata antara ketersediaan informasi dan kemampuan pengguna dalam memproses berita-berita yang ada.

Lebih lanjut, studi dari Putri & Purnomo (2025) mengungkap bahwa FOMO dan pengaruh *financial influencer* di media sosial memiliki efek positif yang signifikan terhadap keputusan investasi di pasar kripto, dengan menguatkan peran psikologis dan emosional dalam perilaku investor kripto, terutama di kalangan generasi muda. Penelitian lain oleh Aritonang & Hariwibowo juga menunjukkan bahwa fenomena FOMO dapat diidentifikasi melalui analisis sentimen pada percakapan media sosial dalam konten kripto, yang mengindikasikan tingginya peran psikologis dan sosial dalam mendorong para pemula membuat keputusan investasi yang seringkali bersifat impulsif.

Berdasarkan kondisi tersebut, perilaku impulsif investor pemula bukan semata-mata disebabkan oleh faktor psikologis, tetapi juga karena keterbatasan alat bantu dalam memproses informasi. Aplikasi yang tersedia saat ini masih menyajikan berita secara mentah tanpa penyederhanaan dan tanpa analisis sentimen otomatis yang terintegrasi. Hal ini

menyebabkan investor harus melakukan interpretasi sendiri terhadap berita yang kompleks, padahal tidak semua pengguna memiliki literasi finansial yang memadai.

Dari perspektif sosial-ekonomi, Indonesia tercatat sebagai salah satu negara dengan jumlah investor kripto tertinggi di dunia. Bappebti (2024) melaporkan bahwa jumlah investor pasar kripto di Indonesia telah menembus 19 juta orang, melampaui investor pasar modal tradisional. Di sisi lain, laporan OJK (2022) melaporkan bahwa tingkat literasi keuangan digital masyarakat masih sangat rendah. Kondisi ini semakin memperjelas adanya kesenjangan antara ketersediaan informasi dan kemampuan pemrosesan informasi oleh investor, khususnya pemula.

Kemajuan teknologi *Natural Language Processing (NLP)* dalam beberapa tahun terakhir telah membuka peluang besar untuk mengatasi permasalahan ini. Teknologi ini mampu meringkas teks (*summarization*) dan klasifikasi sentimen. Penelitian *Kraaijeveld & De Smedt (2020)* juga membuktikan bahwa terdapat keterkaitan yang kuat antara sentimen publik dalam berita dan media sosial dengan pergerakan harga aset kripto. Oleh karena itu, diperlukan sebuah pendekatan cerdas menggunakan model Deep Learning terkini, seperti **DeBERTa-v3** untuk klasifikasi dampak berita yang akurat serta **Generative Model FLAN-T5** untuk menghasilkan interpretasi naratif yang mudah dipahami. Implementasi NLP dalam kripto bukan hanya relevan, tetapi juga menjadi inovasi yang penting dalam financial technology.

Selain itu, pemilihan model DeBERTa-v3 didorong oleh keunggulan arsitekturnya yang menggunakan *disentangled attention mechanism* dan teknik *pre-training* yang lebih optimal dibandingkan BERT konvensional. Model ini terbukti menunjukkan peningkatan performa pada berbagai tes yang melibatkan *Natural Language Understanding (NLU)*, seperti GLUE dan SuperGLUE, seperti yang dijelaskan oleh Pengcheng He, Jianfeng Gao, dan Weizhu Chen dalam penelitian mengenai DeBERTa-v3: *Improving DeBERTa using ELECTRA-Style Pre-Training with Gradient-Disentangled Embedding Sharing*. Peningkatan tersebut membuktikan bahwa DeBERTa-v3 memiliki kemampuan *context representation* yang lebih baik, sehingga lebih cocok untuk tugas klasifikasi sentimen pada teks berita kripto yang kompleks dengan istilah teknis.

Sementara itu, penggunaan FLAN-T5 sebagai model generatif didasarkan pada pendekatan *instruction tuning* yang membuat model lebih adaptif dalam berbagai tugas

text-to-text, termasuk kemampuannya untuk meringkas secara abstraktif. Penelitian yang dilakukan oleh Jason Wei dkk. dalam tulisan *Finetuned Language Models are Zero-Shot Learners* menunjukkan bahwa model yang di *tuning* dengan *prompt* (FLAN), secara signifikan meningkatkan performa *zero-shot* dan generalisasi lintas tugas dibandingkan model T5 standar. Hal tersebut membuktikan bahwa penggunaan FLAN-T5 dalam menghasilkan ringkasan berita kripto lebih baik untuk menyediakan konten yang lebih informatif, efektif, dan mudah untuk dipahami investor pemula.

Selain memenuhi kebutuhan pengguna, aplikasi ini juga berfungsi sebagai acuan inovasi dalam implementasi NLP dan web application pada bidang aset digital. Integrasi NLP untuk AI Summarization, sentiment analysis, dan fitur analitik pasar dalam satu platform menjadikan aplikasi ini sebagai contoh nyata penerapan teknologi cerdas yang dapat dikembangkan lebih lanjut oleh akademisi maupun industri. Aplikasi ini juga membuktikan bahwa NLP dapat digunakan tidak hanya untuk otomatisasi konten, tetapi juga untuk meningkatkan literasi finansial dan kualitas pengambilan keputusan dalam berinvestasi.

Dengan demikian, penelitian ini tidak hanya menghasilkan aplikasi pendukung investasi dalam pasar kripto, tetapi juga berkontribusi untuk meningkatkan literasi dan praktik finansial, yaitu dengan menunjukkan bagaimana *Artificial Intelligence* (AI) dapat mempermudah akses informasi dan memajukan inovasi dalam teknologi finansial.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan di bagian pertama, terdapat beberapa poin permasalahan utama yang menjadi acuan dilakukannya penelitian ini. Permasalahan ini muncul karena tingginya perkembangan volume informasi mengenai aset kripto, kompleksitas bahasa berita, keterbatasan fitur di platform yang sudah ada, dan rendahnya tingkat literasi keuangan digital para investor pemula. Oleh karena itu, penelitian ini merumuskan beberapa poin permasalahan sebagai berikut.

- Bagaimana memanfaatkan model NLP DeBERTa-v3 dan FLAN-T5 untuk melakukan peringkasan berita dan analisis sentimen secara otomatis terhadap berita kripto yang beredar?

- Bagaimana sistem peringkasan dan analisis berita ini dapat membantu investor kripto pemula menghindari keputusan investasi yang emosional akibat *Fear of Missing Out* (FOMO) dan *panic selling*?

1.3. Ruang Lingkup

Penelitian ini berfokus pada pengembangan sistem berbasis web yang mengintegrasikan kecerdasan buatan untuk menginterpretasi data tekstual di pasar mata uang kripto. Lingkup penelitian dibatasi pada poin-poin berikut.

1.3.1. Sumber Data

Jenis data yang digunakan dalam penelitian ini merupakan artikel berita dan pengumuman resmi yang berkaitan dengan kripto. Data yang digunakan ditarik secara *near real-time* yang bersumber dari API CryptoPanic, sebuah platform yang telah menggabungkan beberapa portal media. Selain itu, penelitian ini berfokus pada pemrosesan teks dalam bahasa Inggris.

1.3.2. Batasan Pemrosesan NLP

- Ekstraksi *Metadata*: Memperoleh informasi berita secara terstruktur (sumber, waktu publikasi, dan referensi tautan) melalui integrasi API agregator berita.
- Interpretasi Naratif: Menggunakan *Generative Model* (FLAN-T5) untuk menghasilkan interpretasi kontekstual berita sebanyak 1–2 kalimat yang mudah dipahami.
- Klasifikasi Multidimensi menggunakan model DeBERTa-v3 untuk:
 - *Categorization* (klasifikasi kategori berita, *single-label*).
 - *Impact Level* (klasifikasi tingkat dampak, ordinal).
 - *Target Audience* (klasifikasi *multi-label* untuk menentukan siapa yang terdampak).
 - *Market Pressure* (analisis sentimen pasar).
- Deteksi Kebaruan (Novelty): Menggunakan *Embedding model* (all-MiniLM-L6-v2) untuk mengukur *cosine similarity* berita saat ini dengan berita dahulu untuk menentukan tingkat kebaruan informasi.

- Entitas Terkait: Menggunakan teknik *Named Entity Recognition* (NER) yang dikombinasikan dengan *Dictionary-based Entity Linking* untuk mengidentifikasi koin yang disebutkan dalam teks.

1.3.3. Batasan Waktu dan Objek

- Rentang Waktu Data: Sistem akan memproses data dalam rentang waktu 24 jam terakhir agar interpretasi yang diberikan tetap relevan dengan kondisi pasar terkini.
- Aset Kripto: Analisis difokuskan pada aset kripto dengan kapitalisasi pasar terbesar, yaitu *Top 10* berdasarkan *Market Cap*.
- Arsitektur Sistem: Sistem dibangun menggunakan arsitektur *Single-Backend* berbasis FastAPI (Python) untuk memastikan integrasi model NLP yang efisien dan responsif terhadap *frontend* ReactJS.

1.3.4. Target Pengguna

- *Trader* di pasar kripto, terutama untuk pemula.
- Investor yang membutuhkan sumber informasi dengan cepat, berita yang dapat langsung dipahami, indikasi tren harga, dan pengelolaan *event* secara personal.

1.4. Tujuan dan Manfaat

1.4.1. Tujuan

Tujuan dilakukannya penelitian ini adalah memberikan kemudahan bagi investor crypto dalam melakukan analisis pasar dan memberi *decision support* dalam kegiatan jual beli asset crypto melalui interpretasi berita, adapun fitur yang ditujukan untuk kemudahan interpretasi berita seperti:

- Ringkasan interpretatif berita
- Klasifikasi kategori berita
- Estimasi tingkat dampak berita
- Identifikasi pihak terdampak
- Estimasi rentang waktu dampak
- Deteksi kebaruan berita
- Analisis pergerakan potensial pasar
- Identifikasi aset yang terdampak

1.4.2. Manfaat

Akademis

- Penelitian ini diharapkan mampu memberikan kontribusi keilmuan tentang pengembangan *Natural Language Processing* (NLP) dalam dunia finansial khususnya pada pasar kripto yang memiliki data sangat volatile.
- Penelitian ini diharapkan mampu mengedukasi masyarakat luas tentang pengaruh berita dan sentimen pasar terhadap pergerakan harga pasar kripto

Praktis

- Memberikan *decision support* bagi investor kripto berdasarkan analisis informasi yang dilakukan menggunakan berita dan sentimen pasar yang beredar.
- Membantu investor menyaring berita dan informasi yang berkaitan dengan koin kripto serta memberikan prediksi tren pasar yang terkomputerisasi
- Memastikan investor tidak tertinggal berita atau event penting yang dapat mempengaruhi pergerakan pasar.

1.5. Metodologi Penelitian

1.5.1. Pengumpulan Data

Proses pengumpulan data dilakukan secara otomatis dengan *ingestion* **CryptoPanic API** sebagai agregator berita utama. Sistem dirancang untuk melakukan penarikan data dalam bentuk *batch* dengan interval waktu tertentu (setiap 15 hingga 30 menit) dengan tujuan dapat menjaga aktualitas informasi bagi investor (*near real-time*). Penggunaan API *aggregator* dipilih karena kemampuannya dalam menyatukan berbagai sumber berita kredibel (seperti Cointelegraph dan CoinDesk) ke dalam satu pintu akses, sehingga meningkatkan efisiensi arsitektur sistem.

Strategi penarikan data secara *batching* didukung oleh teori Gharehchopogh & Abdollahzadeh (2021), yang menyatakan bahwa dalam sistem berbasis AI, pemrosesan data dalam bentuk *batch* memungkinkan optimalisasi sumber daya komputasi (CPU/GPU) saat menjalankan model *deep learning* yang intensif seperti *Transformer*. Selain itu, Vuppalapati (2024) menekankan bahwa untuk aplikasi yang membutuhkan aktualitas tinggi namun

memiliki keterbatasan sumber daya API, metode *near real-time* melalui *batching* merupakan solusi teknis yang paling stabil dibandingkan *streaming* murni untuk menjaga konsistensi data sebelum memasuki tahap *preprocessing*.

Data yang diambil mencakup teks *headline* dan *news body* sebagai input utama bagi model NLP, serta *metadata* krusial seperti identitas sumber media, tautan referensi, dan waktu publikasi (*timestamp*). Seluruh data mentah tersebut dikonversi ke dalam format **JSON** untuk menjamin kompatibilitas antar komponen sistem. Metode *batching* ini mendukung efisiensi pada tahap *Novelty Detection*, di mana sekumpulan berita baru dalam satu periode dapat dibandingkan secara terhadap *entry database historical* menggunakan skor *cosine similarity* untuk menyaring informasi yang bersifat repetitif sebelum disajikan kepada pengguna.

1.5.2. Preprocessing Data

Sebelum memasuki model NLP, data teks harus melalui tahap *preprocessing* untuk menghilangkan *noise* yang dapat menurunkan akurasi model. Tahap ini meliputi penghapusan tag HTML, karakter khusus, dan simbol-simbol non-semantik yang sering muncul dalam hasil penarikan data dari API. Setelah teks dibersihkan, teks akan dinormalisasi untuk menangani kontraksi kata dan penyesuaian huruf. Berbeda dengan pendekatan NLP tradisional, penelitian ini mempertahankan struktur tanda baca dan penggunaan huruf kapital (*cased text*). Hal ini didasari oleh argumen He et al. (2021) bahwa model *Transformer* seperti DeBERTa sangat bergantung pada informasi kontekstual dan sintaksis untuk menghasilkan representasi semantik yang akurat.

Tahap yang terakhir adalah tokenisasi, di mana teks akan dipecah menjadi unit-unit *sub-word* yang kompatibel dengan arsitektur model *Transformer* yang digunakan, untuk memastikan representasi numerik teks tetap akurat secara semantik. Setiap model memiliki *tokenizer* spesifiknya masing-masing (misalnya: *DeBERTaTokenizer*, *T5Tokenizer*). Penggunaan *sub-word tokenization* ini, sebagaimana dijelaskan oleh Vaswani et al. (2017); Raffel et al. (2020) dalam penelitian fundamental arsitektur *Transformer*, sangat efektif untuk menangani masalah *Out-of-Vocabulary* (OOV) yang sering terjadi pada terminologi kripto yang baru muncul. Dengan memecah kata menjadi unit yang lebih kecil, sistem memastikan bahwa representasi numerik teks tetap akurat secara semantik tanpa kehilangan informasi penting dari kosakata teknis.

1.5.3. Implementasi Model NLP

Model **DeBERTa-v3** digunakan untuk klasifikasi multidimensi/ multitugas. Model ini unggul dalam memahami konteks bahasa yang kompleks melalui mekanisme *disentangled attention*, di mana setiap kata dipecah menjadi dua vector (*content* dan *position*) sehingga interaksi antar kata dapat dihitung secara lebih presisi melalui matriks atensi yang terurai. He et al.(2019) menunjukkan bahwa dengan arsitektur *disentangled attention* representasi semantik mengalami peningkatan jika dibandingkan dengan BERT ataupun RoBERTa konvensional. Dalam pengujian model menggunakan beberapa tugas NLU **DeBERTa** memiliki kemampuan generalisasi yang unggul dan konsisten dibandingkan dengan beberapa model lain seperti BERT, RoBERTa, XLNet, dan ELECTRA (He et al., 2019, pp. 8-10). Model ini digunakan untuk melakukan klasifikasi *single-label* untuk kategori berita, klasifikasi ordinal untuk tingkat dampak berita, serta klasifikasi *multi-label* untuk identifikasi audiens yang terdampak.

Model **FLAN-T5** digunakan untuk interpretasi naratif. Berbeda dengan ringkasan tradisional yang hanya memotong kalimat, model generatif **FLAN-T5** digunakan untuk *abstractive summarization*. Model ini berbasis arsitektur *encoder-decoder* yang menggunakan mekanisme *relative position bias* untuk memahami urutan kata dan dioptimalkan melalui *instruction fine-tuning* pada ribuan tugas berbeda agar mampu memproses segala jenis masalah NLP dalam format *text-to-text* yang adaptif terhadap *prompt* atau instruksi manusia. Satya et al. (2025) melalui evaluasi kuantitatifnya FLAN-T5 memperoleh score ROUGE-1 sebesar 72%, ROUGE-2 sebesar 61.94%, dan ROUGE-L sebesar 67.68% menandakan model FLAN-T5 mampu menghasilkan ringkasan abstraktif yang koheren dan relevan. Dengan teknik *prompting* yang tepat, model ini mensintesis informasi kompleks menjadi 1-2 kalimat penjelasan yang objektif.

Model embedding **all-MiniLM-L6-v2** dapat digunakan untuk deteksi kebaruan (*Novelty Detection*). Setiap berita baru diubah menjadi vektor dimensi 384. Lalu sistem menghitung skor *cosine similarity* antara berita tersebut dengan berita di dalam *database*. Jika tingkat kemiripan rendah, sistem akan melabeli berita sebagai “*High Novelty*” yang akan membantu investor menyaring pengulangan informasi. Keputusan penggunaan model all-MiniLM-L6-v2 didasari dengan analisa hasil penelitian (Colangelo et al., 2025, pp. 7-11) dimana hasil kuantitatif pengujian 50 artikel, model all-miniLM-L6-v2 mampu mendapatkan hasil *mean similarity* sebesar 0.66 ± 0.04 sedikit di bawah model dengan hasil terbaik mpnet

(0.71 ± 0.04), dengan waktu encoding yang lebih singkat (9 detik banding 98 detik melalui eksperimen 5000 dokumen) sehingga lebih cocok digunakan untuk aplikasi berbasis *realtime*.

NER (*Named Entity Recognition*) digunakan untuk ekstraksi entitas yang dikombinasikan dengan metode *Dictionary-based Entity Linking*, sehingga sistem dapat secara otomatis mengidentifikasi entitas aset kripto spesifik yang disebutkan dalam berita. Model *covalenthq/cryptoNER* dipilih sebagai arsitektur utama didasari oleh spesialisasinya yang tinggi pada domain aset kripto. Model ini merupakan hasil *fine-tuning* dari arsitektur XLM-RoBERTa-*base* yang telah dilatih secara khusus menggunakan lebih dari 20.000 *metadata* token dan *dataset* kontekstual dari media sosial kripto, seperti yang dicatat oleh Hugging Face (2024). Penggunaan arsitektur berbasis RoBERTa dipilih karena, sebagaimana dijelaskan oleh Vallejo Vera (2024), model ini memiliki kemampuan pemahaman kontekstual yang lebih kuat dibandingkan model BERT konvensional melalui skema *dynamic masking* yang lebih adaptif pada teks domain spesifik.

Melalui evaluasi kuantitatif, Hugging Face (2024) menunjukkan model *cryptoNER* mampu mencapai nilai ***F1-Score*** sebesar 0.9970, yang menandakan akurasi hampir sempurna dalam mengekstraksi entitas seperti simbol aset (misal: *\$BTC*) dan nama token secara otomatis. Penggabungan dengan metode *dictionary-based* memastikan bahwa entitas yang dideteksi oleh model **NER** dapat di-*mapping* secara tepat ke ID aset yang unik, sehingga meminimalisir ambiguitas pada simbol koin yang mirip.

1.5.4. Pengembangan Sistem informasi

Hasil dari model-model **NLP** kemudian diintegrasikan ke dalam sistem informasi berbasis web. Arsitektur sistem menggunakan FastAPI (Python) di sisi *backend* untuk menangani model AI yang intensif dan seluruh proses aplikasi, termasuk inferensi model AI, manajemen data, autentikasi pengguna, dan integrasi dengan database dari *external API*. Di sisi *frontend* menggunakan ReactJS untuk membangun antarmuka yang responsif. *Output* model disajikan dalam modul-modul visual yang mudah dipahami, seperti label dampak berwarna secara otomatis.

Penggunaan FastAPI optimal karena performanya yang baik dan memiliki dukungan *asynchronous* berbasis **ASGI**, hal ini mendorong penanganan proses inferensi model *deep learning* dengan *latency* rendah. Selain itu, karena model **NLP** seperti DeBERTa-v3 dan

FLAN-T5 dikembangkan menggunakan ekosistem Python, penggunaan FastAPI memungkinkan integrasi langsung tanpa *overhead* konversi ke bahasa lain.

Selain menangani proses AI, FastAPI juga mampu berfungsi sebagai *application server* yang mengelola logika bisnis, autentikasi pengguna, manajemen data berita, penyimpanan *news history*, dan komunikasi dengan API eksternal. Dengan demikian, FastAPI menggantikan peran *middleware* yang berfungsi sebagai *unified back-end architecture* yang lebih sederhana namun tetap *scalable*. Terdapat literatur tentang pentingnya *framework* ringan dan *scalable* untuk sistem berbasis AI seperti yang dikaji Söylemez et al. (2022).

Sementara itu, ReactJS digunakan karena memiliki arsitektur berbasis komponen dan *virtual DOM*, yang meningkatkan performa *rendering* serta memudahkan pengelolaan *dashboard* yang dinamis. Pendekatan *single-page application* (SPA) juga terbukti dapat meningkatkan *user experience* dalam sistem web modern, Mokoginta, J., et al. (2024).

1.5.5. Evaluasi Penelitian

Untuk menjamin validitas ilmiah, penelitian ini dievaluasi melalui tiga sudut pandang:

1. Evaluasi Teknis Model Klasifikasi dan Ekstraksi: Mengukur kinerja klasifikasi model DeBERTa-v3 dan kemampuan ekstraksi entitas model cryptoNER. Metrik yang digunakan meliputi **akurasi**, **presisi**, **recall**, dan **F1-score**. Penggunaan *Confusion Matrix* akan diterapkan untuk menganalisis distribusi kesalahan prediksi model pada kategori yang memiliki ambiguitas tinggi.
2. Evaluasi Kualitas Teks Generatif: Menilai kualitas interpretasi naratif dari model **FLAN-T5** menggunakan metrik **ROUGE** (1, 2, dan L) untuk mengukur *lexical overlap*, serta **BERTScore** untuk mengukur *semantic similarity* secara mendalam.
3. Evaluasi Pengguna dan Dampak Perilaku (UAT):
 - a. Pengujian fungsionalitas dan kualitas antarmuka web diukur menggunakan kuesioner berbasis **System Usability Scale (SUS)** untuk menentukan tingkat penerimaan sistem (*acceptability*) secara teknis
 - b. Dampak perilaku responden diukur melalui **Kuesioner Literasi & FOMO** yang dirancang untuk membandingkan tingkat pemahaman

dan kecenderungan investasi impulsif sebelum (*pre-test*) dan sesudah (*post-test*) responden berinteraksi dengan sistem.

- c. Data yang diperoleh dari kedua tahap pengujian tersebut kemudian diolah menggunakan analisis statistik **Paired Sample T-Test**. Pengujian ini menentukan apakah terdapat perbedaan signifikan secara statistik pada perilaku dan literasi responden setelah mendapatkan bantuan informasi dari sistem. Hasil evaluasi ini akan menjadi bukti empiris apakah sistem informasi berbasis AI yang dibangun efektif dalam menanggulangi perilaku investasi emosional pada investor pemula.

1.6. Sistematika Penulisan

Dalam penelitian ini, sistematika penulisan disusun dengan sistematis untuk memberikan gambaran secara terstruktur mengenai isi penelitian dari awal sampai akhir. Adapun penulisan sistematika penelitian ini sebagai berikut.

BAB 1 Pendahuluan

Bab pertama berisikan latar belakang yang menjabarkan kepentingan dan relevansi terhadap topik penelitian, yakni penggunaan *Natural Language Processing (NLP)* dalam interpretasi berita *cryptocurrency*, khususnya untuk meningkatkan pengetahuan investor pemula. Tak hanya itu, bab ini juga mengandung rumusan masalah, ruang lingkup penelitian, tujuan dan manfaat penelitian, metodologi penelitian secara garis besar, dan sistematika penulisan yang memberikan gambaran keseluruhan isi skripsi.

BAB 2 Tinjauan Referensi

Bab ini mengkaji mengenai teori-teori dan penelitian yang sudah ada, yang relevan terhadap topik penelitian ini. Pembahasan ini meliputi konsep dasar *cryptocurrency* dan kecenderungan perilaku investor pemulanya, teori sentimen pasar, *Natural Language Processing (NLP)*, model *Transformer*, DeBERTa-V3, FLAN-T5, *all-MiniLM-L6-v2*, *Named Entity Recognition (NER)*, dan konsep evaluasi model seperti *Accuracy*, *F1-Score*, dan *ROUGE Score*. Selain itu, bab ini juga menguraikan arah pemikiran yang menjadi dasar perancangan sistem yang dikembangkan.

BAB 3 Metodologi Penelitian

Bab ketiga mengandung penjelasan secara rinci tentang metode penelitian yang diterapkan, dimulai dari proses pengumpulan data melalui API CryptoPanic, tahapan *preprocessing text*, implementasi model *NLP* (DeBERTa-v3 untuk klasifikasi multidimensi, FLAN-T5 untuk *abstractive summarization*, *all-MiniLM-L6-v2* untuk *novelty detection*, dan *NER* untuk ekstraksi entitas). Bab ini juga membahas mengenai perancangan arsitektur sistem berbasis web yang menggunakan FastAPI dan ReactJS. Hingga alur sistem, diagram arsitektur, serta skema integrasi model ke dalam aplikasi juga dijelaskan dalam bab ini.

BAB 4 Hasil dan Pembahasan

Bab ini menjabarkan hasil implementasi sistem, dan evaluasi performa model. Evaluasi dilakukan melalui performa model. Evaluasi tersebut dilakukan dengan pengujian teknis melalui metrik klasifikasi (*Accuracy*, *Precision*, *Recall*, *F1-Score*) untuk model DeBERTa-v3. Untuk FLAN-T5 akan dilakukan evaluasi kualitas ringkasan menggunakan metrik *ROUGE*, serta evaluasi pengguna (*User Acceptance Test*) melalui metode *pre-test* dan *post-test* kepada para pengguna, khususnya investor pemula. Selain itu, bab ini juga membahas analisis hasil pengujian, serta interpretasi terhadap temuan penelitian.

BAB 5 Simpulan dan Saran

Bab terakhir berisikan kesimpulan yang ditarik, berdasarkan hasil penelitian dan pembahasan yang telah dilakukan. Selain itu, bab ini juga mengandung saran untuk pengembangan di penelitian selanjutnya, baik dari sisi peningkatan model *NLP*, perluasan domain aset kripto, penambahan fitur, hingga kemampuan untuk integrasi dengan sistem prediksi harga berbasis *time-series* di masa mendatang.

2. TINJAUAN REFERENSI

2.1. Landasan Teori

2.1.1. Aset Kripto

Aset Kripto merupakan sebuah bentuk aset digital yang menggunakan teknologi kriptografi yang mengamankan transaksi, serta mengontrol penciptaan jumlah aset. Aset ini beroperasi secara terus-menerus di atas teknologi *blockchain*, yang merupakan sistem pencatatan terdistribusi, mendorong transparansi dan keamanan yang baik tanpa perlu adanya pihak ketiga sebagai perantara (Narayanan et al., 2016). Karakteristik utama aset kripto adalah desentralisasi, dimana transaksi aset dilakukan secara *peer-to-peer* tanpa adanya keterlibatan otoritas pusat.

Seiring kripto berkembang, aset ini tidak hanya berfungsi sebagai alat pembayaran digital, tetapi juga sebagai alat investasi yang memiliki volatilitas tinggi. Volatilitas tinggi tersebut disebabkan oleh beberapa faktor seperti sentimen pasar, aktivitas perdagangan yang tinggi, serta eksposur media dan informasi publik. Penelitian terkini mengungkapkan bahwa pasar aset kripto sangat dipengaruhi oleh faktor spekulatif dan perubahan perilaku investor yang tak terduga. Hal tersebut berpotensi menyebabkan fluktuasi harga yang signifikan dalam waktu singkat.

Tak hanya itu, struktur pasar kripto yang berbasis digital, beroperasi di kalangan masyarakat global, tak henti selama 24 jam menjadikan arus informasi sebagai faktor utama yang mempengaruhi pergerakan harga. Oleh karena itu, pemahaman kripto secara konseptual serta pengetahuan informasi dan berita merupakan elemen penting dalam proses pengambilan keputusan investasi aset kripto.

2.1.2. Perilaku Investor Aset Kripto Pemula

Pada umumnya, perilaku investor aset kripto memiliki karakteristik yang cenderung berbeda dengan pasar keuangan lain. Hal ini didukung oleh volatilitas harga aset yang tinggi, kegiatan pasar yang berlangsung selama 24 jam, dan dominasi investor ritel dalam ekosistem kripto. Banyak penelitian telah

menunjukkan bahwa investor kripto, terutama pemula, cenderung dipengaruhi faktor psikologis dan emosional dalam pengambilan keputusan dalam berinvestasi.

Salah satu fenomena yang paling dominan adalah *Fear of Missing Out* (FOMO), yang merupakan kondisi dimana investor merasa takut kehilangan peluang mencapai keuntungan. Hal tersebut membuat mereka terdorong untuk melakukan pembelian terhadap suatu aset secara impulsif, tanpa melakukan analisis yang dalam. Penelitian oleh Li et al. (2025) menunjukkan bahwa FOMO membawa peran yang kuat dalam perdagangan aset kripto, dimana investor cenderung mau mengambil resiko yang tinggi akibat dorongan emosional. Selain itu, peningkatan harga aset kripto dapat memicu masuknya investor baru secara masif, didorong oleh kemauan untuk memperoleh keuntungan besar dalam waktu jangka pendek.

Selain dari faktor psikologis, rendahnya tingkat literasi keuangan juga menjadi faktor utama yang mempengaruhi perilaku investasi investor pemula. Klepacki (2025) mengungkapkan bahwa kurangnya pemahaman terhadap cara kerja pasar dan risiko investasi, menyebabkan rentan terhadap pengambilan keputusan yang impulsif dan spekulatif. Dengan demikian, secara global, perilaku investor kripto pemula dapat dikategorikan sebagai perilaku yang sangat dipengaruhi oleh faktor emosi, sosial, dan tingkat pengetahuan yang rendah.

Di Indonesia, fenomena tersebut juga bertumbuh secara signifikan dengan jumlah investor kripto yang berkembang secara pesat dalam beberapa tahun terakhir. Data dari Badan Pengawas Perdagangan Berjangka Komoditi (Bappebti), menunjukkan bahwa investor kripto di Indonesia telah tembus sebanyak puluhan juta pengguna, dengan populasi terbesar yakni berasal generasi muda. Namun, peningkatan jumlah tersebut juga tidak bergerak sebanding dengan tingkat literasi keuangan yang cukup.

Menurut laporan Otoritas Jasa Keuangan (OJK, 2022), literasi keuangan pasar digital masyarakat Indonesia masih cukup rendah. Kondisi tersebut menyebabkan banyak investor pemula di Indonesia cenderung mengambil keputusan berinvestasi hanya dari mengikuti tren pasar, rekomendasi

influencer, serta sentimen yang berkembang di sosial media tanpa melakukan analisis aset yang mendalam.

Penelitian oleh Putri dan Purnomo (2025) juga mendukung bahwa fenomena FOMO dan pengaruh *financial influencer* memiliki pengaruh yang besar terhadap pengambilan keputusan investasi Cryptocurrency di Indonesia. Hal tersebut menunjukkan bahwa perilaku investor pemula di Indonesia, tak hanya dipengaruhi oleh faktor global seperti volatilitas pasar dan arus informasi, tetapi juga faktor umum seperti rendahnya literasi keuangan dan tingginya pengaruh sosial.

2.1.3. Teori Sentimen Pasar

Sentimen Pasar adalah suatu persepsi atau sikap kolektif investor terhadap sebuah kondisi aset atau pasar dalam sebuah periode. Pada umumnya, sentimen dikategorikan sebagai positif (*bullish*), negatif (*bearish*), dan netral. Tipe sentimen ini terbentuk dari informasi seperti berita, media sosial, opini publik, yang kemudian akan mempengaruhi cara investor mengambil keputusan dalam berinvestasi.

Dalam konteks pasar kripto, sentimen pasar memiliki peran yang kuat karena karakteristik pasar kripto yang didominasi oleh investor ritel serta volatilitas harga yang tinggi. Perubahan persepsi investor terhadap suatu sumber informasi dapat merubah persepsi dan keputusan investasi secara cepat, yang juga berpengaruh terhadap perubahan harga yang drastis. Penelitian menunjukkan bahwa pasar kripto lebih sensitif terhadap sentimen dibandingkan pasar keuangan yang lain, sehingga reaksi investor terhadap berita dan informasi menjadi faktor utama dalam pergerakan harga (Corbet et al., 2020).

Tak hanya itu, perkembangan media digital memicu peningkatan penyebaran informasi yang dapat membentuk sentimen pasar secara luas dalam waktu singkat. Penelitian oleh Kraaijeveld dan De Smedt (2020) mengungkapkan bahwa sentimen publik yang terbentuk dari media sosial memiliki hubungan dengan pergerakan harga aset kripto. Hal tersebut membuktikan bahwa persepsi kolektif investor dapat menjadi pengetahuan penting dalam memahami arah pergerakan harga pasar.

Dengan demikian, sentimen pasar adalah sebuah hal signifikan yang menjadi salah satu kunci dalam mengetahui dan menguasai dinamika pasar kripto. Perubahan opini dan emosi investor dapat secara langsung mempengaruhi keputusan investasi, yang juga berpengaruh bagi pergerakan aset kripto.

2.1.4. Natural Language Processing

Natural Language Processing merupakan bagian dari kecerdasan buatan (*Artificial Intelligence*) yang berfokus pada interaksi antara komputer dan bahasa manusia untuk memberikan kemampuan dalam komputer untuk memahami, menginterpretasikan, dan menghasilkan bahasa manusia yang bermakna.

Menurut Jurafsky & Martin (2024), fokus utama dari NLP adalah pengembangan algoritma yang mampu menangani *natural language*, baik dalam bentuk teks maupun suara, untuk menghubungkan *communication gap* antara manusia dan mesin. Tantangan terbesar dalam NLP dari dulu hingga era modern adalah masalah *lexical and syntactic ambiguity*. Bender & Koller (2020) dalam penelitiannya mengenai *meaning* dan *form* menekankan bahwa mesin seringkali kesulitan membedakan makna yang tersirat karena bahasa sangat bergantung pada konteks dunia nyata, bukan sekadar statistik kata.

Seiring perkembangan teknologi, NLP telah bertransformasi dari sistem yang bersifat *rule-based* menuju pendekatan *deep learning*. Li et al. (2020) mencatat bahwa penggunaan *neural networks* telah mengubah cara mesin menangani tugas-tugas kompleks seperti *sentiment analysis*, *entity extraction*, hingga *automatic summarization* dengan tingkat akurasi yang jauh melampaui metode tradisional. Dalam skenario analisis berita keuangan seperti *cryptocurrency*, implementasi NLP menjadi instrumen krusial untuk mengkonversi data tekstual yang tidak terstruktur menjadi *structured insights* yang dapat digunakan investor untuk mengambil keputusan secara lebih cepat dan objektif.

2.1.5. Arsitektur Transformer

Arsitektur Transformer merupakan sebuah perkembangan dalam bidang NLP yang pertama kali diperkenalkan oleh Vaswani et al. (2017) melalui *paper* yang berjudul "*Attention is All You Need*" dan penelitian oleh Raffel et al. (2020). Berbeda dengan pendahulunya seperti *Recurrent Neural Networks* (RNN) atau *Long Short-Term Memory* (LSTM) yang memproses data secara sekuensial, Transformer mengandalkan mekanisme *Parallel Processing*. Hal ini memungkinkan model untuk memproses seluruh urutan kata dalam sebuah kalimat secara bersamaan, sehingga jauh lebih efisien dan *scalable* untuk menangani *large-scale datasets*.

Inovasi utama dari Transformer terletak pada mekanisme *Self-Attention* (sering disebut juga *Intra-Attention*). Mekanisme ini memungkinkan model untuk memberikan "bobot" atau perhatian yang berbeda-beda pada setiap kata dalam sebuah kalimat, tergantung pada relevansi dalam kontekstualnya. Sebagai contoh, dalam kalimat "*The bank was closed due to high river levels*", mekanisme *Self-Attention* akan membantu model memahami bahwa kata "*bank*" di sini merujuk pada tepi sungai (*river bank*), bukan lembaga keuangan, karena adanya keterikatan kuat dengan kata "*river*". Proses ini dilakukan melalui mekanisme self-attention yang melibatkan perhitungan Query (Q), Key (K), dan Value (V), di mana bobot perhatian dihitung menggunakan kesesuaian antara Q dan K, kemudian digunakan untuk menghasilkan representasi output berbasis V. Mekanisme ini memungkinkan model untuk menangkap hubungan antar kata dalam jarak jauh (*long-range dependencies*) secara efektif (Khan et al., 2022).


Selain itu, karena Transformer tidak memproses kata secara berurutan, model ini menggunakan *Positional Encoding* untuk memberikan informasi mengenai posisi atau urutan setiap kata dalam sebuah teks. Komponen lain yang juga penting adalah *Multi-Head Attention*, di mana model menjalankan beberapa mekanisme *attention* secara serentak untuk menangkap berbagai aspek hubungan antar kata dari sudut pandang yang berbeda. Arsitektur ini terbagi menjadi dua bagian utama: *Encoder* untuk memahami *input* dan *Decoder* untuk menghasilkan *output*. Kombinasi dari seluruh komponen inilah yang menjadi

fondasi bagi model-model *state-of-the-art* saat ini seperti DeBERTa, GPT, dan FLAN-T5.

2.1.6. DeBERTa (Decoding-enhanced BERT with Disentangled Attention)

DeBERTa (Decoding-enhanced BERT with Disentangled Attention) merupakan salah satu hasil pengembangan model *Bidirectional Encoder Representations from Transformers* (BERT). Model ini dirancang untuk meningkatkan kemampuan pemahaman bahasa alami manusia (*Natural Language Understanding*). Model ini diperkenalkan oleh He et al. (2021), tujuannya yakni untuk mengatasi keterbatasan BERT dalam merepresentasikan hubungan antar kata dalam sebuah kalimat.

Perbedaan utama antara DeBERTa dan model transformer lainnya adalah pada penggunaan *disentangled attention mechanism*. Berbeda dengan model *transformer* standar yang langsung menggabungkan informasi posisi ke dalam makna kata, arsitektur DeBERTa memisahkan setiap kata menjadi dua vektor independen: vektor yang merepresentasikan konten dan vektor yang merepresentasikan posisi relatif. Dengan pendekatan ini, model dapat memahami konteks kalimat secara lebih akurat karena hubungan antar kata dihitung berdasarkan makna dan letak relatifnya secara terpisah, sehingga memungkinkan model untuk menangkap dependensi antar kata yang berjauhan secara lebih presisi.



Gambar 2.1 High-Level Overview of the DeBERTa Model's Architecture


Sumber: Abraha, T., & Nazir, A. (2024)

Tak hanya itu, DeBERTa juga menggunakan teknik *enhanced mask decoder* yang ditingkatkan untuk memberikan informasi posisi absolut kata tepat. Sehingga memungkinkan model untuk prediksi token yang lebih baik selama proses *pre-training*. Kombinasi dari kedua pendekatan tersebut terbukti dapat meningkatkan performa model, terbukti dalam benchmark *Natural Language Understanding* seperti GLUE dan SuperGLUE. Dari hasil tes tersebut, DeBERTa menunjukkan kemampuannya dalam memahami kalimat teks yang kompleks dengan baik.

Di penelitian ini, DeBERTa digunakan untuk melakukan klasifikasi sentimen terhadap teks dari berita kripto. Pemilihan model ini didasarkan pada kemampuannya yang dapat memahami konteks bahasa teknis dan kompleks, yang umum ditemukan dalam berita dan artikel yang bertema keuangan dan kripto. DeBERTa diharapkan mampu menghasilkan klasifikasi yang lebih tepat, sehingga dapat membantu dalam memahami kecenderungan pasar berdasarkan informasi yang tersedia.

2.1.7. Model FLAN T-5 (Fine-tuned Language Net)

FLAN-T5 merupakan versi terancang dari model T5 (*Text-to-Text Transfer Transformer*) yang dikembangkan oleh tim Google Research. Secara arsitektur, FLAN-T5 tetap mempertahankan struktur *Encoder-Decoder* yang menjadi ciri khas keluarga model T5. Perbedaannya terletak pada proses *training* yang jauh lebih kuat dan spesifik. Berbeda dengan model standar yang dilatih secara *unsupervised*, menurut Chung et al. (2022), model ini dioptimalkan melalui metode *Instruction Fine-Tuning* pada lebih dari 1800 tugas NLP yang berbeda dan diformat ke dalam bentuk instruksi bahasa alami. Hal ini memungkinkan model memiliki kemampuan *zero-shot learning* yang sangat baik, di mana model ini mampu menjalankan perintah baru yang belum pernah dilihat sebelumnya selama proses latihan.



Gambar 2.2 Architectural Diagram of FLAN T5

Sumber: Putra, C., Arlis, S., & Nurcahyo, G. W. (2025).


Dalam struktur internalnya, bagian *Encoder* bertugas untuk memahami dan memetakan konteks dari teks berita kripto yang kompleks ke dalam representasi matematis. Selanjutnya, bagian *Decoder* akan membangkitkan teks baru berdasarkan pemahaman tersebut. Melalui pendekatan *Text-to-Text Framework*, FLAN-T5 menyatukan seluruh tugas NLP ke dalam format *input* dan *output* yang seragam berupa teks murni. Fleksibilitas ini membuat arsitektur FLAN-T5 sangat adaptif terhadap *prompt engineering*, di mana sistem dapat diarahkan secara spesifik melalui instruksi (seperti "*Summarize the following crypto news in 2 sentences*") untuk menghasilkan ringkasan objektif yang mudah dipahami oleh investor pemula. Karakteristik inilah yang menjadikan FLAN-T5 ideal sebagai mesin interpretasi berita *near real-time* dalam penelitian ini.

Dalam konteks tugas *Abstractive Summarization*, FLAN-T5 tidak bekerja dengan cara memotong kalimat asli (*extractive*), melainkan melakukan sintesis informasi untuk menghasilkan kalimat baru yang lebih ringkas dan *human-like*. Selain itu, penggunaan model berbasis T5 dalam ranah finansial

telah terbukti efektif karena kemampuannya menangani terminologi teknis yang kompleks. Li et al. (2023) menjelaskan bahwa model dari keluarga T5 yang telah melewati tahap *fine-tuning* memiliki keunggulan dalam menjaga integritas data numerik dan fakta pasar saat melakukan *summarization*, sehingga meminimalisir risiko *hallucination* (informasi palsu).

2.1.8. all-MiniLM-L6-v2

all-MiniLM-L6-v2 merupakan salah satu model *sentence embedding* yang dikembangkan melalui proses *knowledge distillation* menjadi arsitektur yang ringan dan efisien. Model ini termasuk dalam keluarga Sentence-BERT (SBERT), di mana menurut Reimers & Gurevych (2019), varian Transformer ini dikembangkan untuk memfokuskan hasil representasi vektor kalimat secara semantik. Berbeda dengan model BERT konvensional yang menghasilkan representasi pada tingkat kata tunggal (*token level*), arsitektur all-MiniLM-L6-v2 menerapkan mekanisme *mean pooling* pada *output* tokennya.



Gambar 2.3 Diagram Sekuensial all-MiniLM-L6-v2

Sumber: Dokumentasi Pribadi

Secara arsitektur, mekanisme *mean pooling* ini berfungsi untuk merata-ratakan nilai dari seluruh kata dalam satu kalimat sehingga menghasilkan satu vektor tunggal berdimensi 384. Vektor inilah yang merepresentasikan makna keseluruhan dari sebuah kalimat atau paragraf dalam ruang koordinat matematis. Melalui pelatihan pada 1 miliar pasangan kalimat dengan pendekatan *contrastive learning*, model ini mampu menangkap kemiripan makna (*semantic similarity*) secara akurat dibandingkan dengan pendekatan tradisional berbasis

kata kunci seperti TF-IDF. Dengan menggunakan metode *cosine similarity*, sistem dapat menghitung kedekatan makna antara dua berita secara numerik dalam rentang skor 0 hingga 1.

Dari hasil penelitian komparatif yang dilakukan oleh Colangelo et al. (2025) setelah melakukan pengujian terhadap 50 artikel ilmiah ditemukan bahwa model all-MiniLM-L6-v2 mampu menghasilkan mean similarity sebesar 0.66 ± 0.04 , sedikit di bawah model dengan performa terbaik yaitu mpnet-base-v2 yang mencapai 0.71 ± 0.04 , dengan margin perbedaan waktu *encoding* yang jauh lebih singkat untuk model all-MiniLM-L6-v2 yaitu hanya 9 detik jika dibandingkan dengan mpnet-base-v2 98 detik untuk eksperimen pada 5000 dokumen. Yin & Zhang (2024) juga menunjukkan bahwa model all-MiniLM-L6-v2 mampu mendeteksi *semantic similarity* secara efektif pada kalimat dengan struktur berbeda yang memiliki makna serupa.


Pada penelitian ini, all-MiniLM-L6-v2 digunakan untuk *novelty detection* untuk mendeteksi kebaruan berita. Artikel berita baru akan diubah menjadi vektor berdimensi 384, lalu skor *cosine similarity* antara vektor tersebut akan dihitung dan dibandingkan dengan berita-berita sebelumnya yang tersimpan dalam database. Nilai berita yang melewati *threshold* yang ditentukan akan diberi label sebagai “*High Novelty*”, yang menandakan bahwa berita tersebut berisi konten terbaru. Pendekatan ini dirancang untuk membantu investor memilih berita dengan berfokus pada berita yang minim akan pengulangan yang berlebih sehingga lebih relevan.

2.1.9. NER

Named Entity Recognition (NER) merupakan salah satu tugas dalam *Natural Language Processing* yang berguna untuk identifikasi dan klasifikasi entity yang disebutkan dalam suatu konteks ke dalam kategori yang sudah ditentukan sebelumnya seperti pemberian label pada potongan frasa atau kalimat menurut jenis entitas nya. Shelar et al.(2020) mengatakan bahwa NER adalah sebuah anotasi otomatis yang memungkinkan sistem untuk mengidentifikasi unit-unit informasi bermakna dalam teks yang tidak berstruktur, yang nantinya dapat digunakan untuk *information retrieval*, *knowledge graph construction*, dan pemrosesan bahasa tingkat lanjut lainnya. Dengan semakin berkembangnya

arsitektur Transformer, pendekatan NER mulai beralih dari menggunakan *rule based architecture* menuju pendekatan *deep learning* dengan menggunakan *pre-trained* model. Li et al. (2020) mengatakan bahwa pendekatan ini konsisten mengungguli metode konvensional dalam mengolah terminologi teknis dalam teks domain-spesifik.

Model NER yang digunakan dalam penelitian ini adalah *cryptoNER*, yang berbasis pada arsitektur XLM-RoBERTa. Secara arsitektur, model ini bekerja pada tingkat *token classification*. Sebagaimana diilustrasikan pada diagram arsitektur di bawah ini, proses dimulai dengan memecah kalimat menjadi unit *token*, di mana setiap *token* akan melewati lapisan *Transformer* untuk dianalisis konteksnya, lalu diakhiri dengan lapisan klasifikasi yang memberikan label spesifik pada setiap kata.



Gambar 2.4 Diagram cryptoNER

Sumber: Dokumentasi Pribadi

Model ini telah melalui tahap *fine-tuning* khusus untuk domain aset kripto menggunakan lebih dari 20.000 metadata *token* dan dataset kontekstual dari media sosial kripto. Vellejo Vera (2024) menyatakan bahwa dengan menggunakan mekanisme *dynamic masking* yang adaptif terhadap teks domain-spesifik, model berbasis RoBERTa ini mampu menghasilkan kemampuan kontekstual yang lebih kuat dibandingkan pendekatan BERT konvensional. Secara kuantitatif, model cryptoNER ini mampu mencapai nilai F1-Score sebesar 0,9970, yang menandakan tingkat akurasi sangat tinggi dalam

identifikasi simbol aset dan nama *token* secara otomatis. Dalam sistem ini, *cryptoNER* berperan penting untuk menghubungkan berita yang relevan langsung ke aset spesifik yang sedang dipantau oleh pengguna.

2.1.10. Evaluasi Model

Evaluasi model menjadi tahap krusial dalam penelitian ini dengan tujuan untuk mengukur sejauh mana performa model dalam menyelesaikan tugasnya secara objektif dan terstruktur. Dalam penelitian ini, evaluasi yang dilakukan dapat dibagi menjadi tiga perspektif yang saling berhubungan, dikarenakan adanya perbedaan karakteristik *output* sehingga membutuhkan pendekatan yang berbeda.

Dalam evaluasi model DeBERTa-v3 dan *cryptoNER*, metrik seperti *accuracy*, *precision*, *recall*, dan *f1-score* berperan sebagai *harmonic mean* dari *precision* dan *recall* yang memberikan keterangan yang lebih seimbang, terutama pada dataset dengan distribusi kelas yang tidak merata yang biasa ditemukan dalam berita keuangan (Shelar et al., 2020). *Confusion Matrix* juga dapat diterapkan untuk menganalisis pola *false-positive* maupun *true-negative* dalam hasil prediksi model yang memiliki kategori ambiguitas yang tinggi. FLAN-T5 dapat diukur menggunakan *metrics* ROUGE-1, ROUGE-2, ROUGE-L yang mengukur tumpang tindihnya leksikal antara hasil ringkasan dengan teks referensi, serta BERTscore yang diperkenalkan oleh Zhang et al. (2020) dengan menggunakan representasi kontekstual berbasis BERT untuk mengukur *semantic similarity* yang lebih mendalam.

User Acceptance Testing (UAT) digunakan untuk evaluasi terhadap penerimaan dan dampak sistem terhadap pengguna melalui dua instrumen. Pertama, menggunakan pendekatan *System Usability Scale* (SUS) yang dikembangkan oleh Lewis (2018) digunakan untuk mengukur tingkat kegunaan UI web secara teknis. Kedua, melalui kuesioner literasi dan FOMO dengan pendekatan *pre-test* dan *post-test*, yang kemudian dianalisis menggunakan uji statistik *paired sample T-Test* untuk menentukan apakah terdapat perbedaan yang signifikan dalam tingkat literasi dan kecenderungan investasi impulsif sebelum dan sesudah pengguna berinteraksi dengan sistem.

2.1.11. Data Flow Diagram

Data Flow Diagram (DFD) merupakan sebuah metode pemodelan, digunakan untuk menggambarkan aliran data dalam suatu sistem. Model ini menunjukkan bagaimana data dialirkan, diproses, disimpan, dan dihasilkan antara entitas eksternal dan sistem, hingga kemana hasilnya diterima oleh pengguna atau sistem lainnya. Model ini fokus terhadap pergerakan dan transformasi data. DFD banyak digunakan pada tahap analisis dan perancangan sistem untuk membantu memahami kebutuhan fungsional secara lebih terstruktur.

Terdapat empat komponen utama dalam DFD, yaitu *external entity* (entitas eksternal), *process flow* (proses), *data flow* (aliran data), dan *data store* (penyimpanan data). Penggunaan DFD dapat membantu pengembang sistem memvisualisasikan interaksi antar komponen dalam sistem untuk mempermudah proses analisis, dokumentasi, hingga implementasi sistem (Seifermann et al., 2022).

2.2. Related Works

2.2.1. Cryptocurrency Sentiment Analysis Using Deep Learning for Market Prediction (Kraaijeveld & De Smedt, 2020)

Penelitian yang dilakukan oleh Kraaijeveld dan De Smedt (2020) dengan judul “*The Predictive Power of Public Twitter Sentiment for Forecasting Cryptocurrency Prices*” mengandung pembahasan mengenai analisis sentimen berbasis media sosial untuk prediksi pergerakan harga aset kripto. Penelitian ini menggunakan data dari media sosial Twitter (sekarang *X*) untuk mendapatkan sentimen publik, yang kemudian dikaitkan dengan harga aset kripto utama seperti Bitcoin dan Ethereum. Metode yang digunakan adalah pendekatan *lexicon-based* dan *machine learning* konvensional seperti *Naive Bayes* dan *Support Vector Machine (SVM)* untuk melakukan analisis dan klasifikasi sentimen dari teks yang ada di sosial media tersebut.

Penelitian ini menunjukkan bahwa sentimen publik yang didapatkan dari Twitter memiliki keterkaitan yang kuat terhadap pergerakan harga aset kripto, sehingga dapat digunakan sebagai sinyal prediktif yang baik. Selain itu,

penelitian ini juga mengidentifikasi bahwa sentimen yang bersifat positif cenderung mendorong peluang kenaikan harga aset, sedangkan sentimen negatif juga memiliki keterikatan terhadap penurunan harga aset di hari berikutnya. Secara teknis, penelitian ini membuktikan bahwa pemrosesan teks dari sumber informasi seperti media sosial dapat bermakna untuk pengembangan fitur baru di suatu aplikasi analisis pasar kripto.

Perbandingan terhadap penelitian ini menunjukkan sejumlah kesamaan dan perbedaan signifikan terhadap pendekatan yang diaplikasikan di skripsi ini. Kedua penelitian ini sama-sama memanfaatkan analisis sentimen terhadap sumber teks yang tidak terstruktur untuk memahami dinamika pasar kripto. Di sisi lain, penelitian ini juga memiliki keterbatasan seperti pada sumber data yang digunakan dalam penelitian Kraaijeveld dan De Smedt hanya terbatas pada media sosial Twitter, dimana unggahan media sosial memiliki karakter bahasa yang informal dan memiliki tingkat kebisingan data yang tinggi. Sebaliknya, penelitian dalam skripsi ini menggunakan berita kripto dari aggregator berita profesional (CryptoPanic) yang berasal dari portal media berkredibilitas tinggi seperti CoinDesk dan CoinTelegraph. Hal tersebut mendorong kualitas tekstual input yang lebih tinggi, terstruktur, dan dapat diandalkan.

Model yang digunakan oleh Kraaijeveld dan De Smedt merupakan pendekatan *machine learning* konvensional yang memiliki keterbatasan dalam memahami bahasa yang kompleks dan ambiguitas semantik. Penelitian yang diusulkan menggunakan model DeBERTa-v3, yang merupakan *Transformer state-of-the-art* menggunakan mekanisme *disentangled attention* dapat menghasilkan pemahaman kontekstual yang lebih dalam terhadap berita kripto yang penuh dengan konteks teknis. Tak hanya itu, penelitian yang sudah dilakukan tersebut tidak menyediakan output yang langsung bisa dipahami oleh pembaca pemula, karena *output*-nya masih berupa prediksi statistik yang mentah dan membutuhkan interpretasi lebih lanjut. Sehingga penelitian kami mengusulkan untuk mengintegrasikan model FLAN-T5 untuk menghasilkan ringkasan interpretatif dengan bahasa yang mudah untuk dipahami. Pendekatan ini membuat informasi yang didapatkan lebih aksesibel dan mudah untuk dikonsumsi oleh para pengguna, terutama investor dengan keterbatasan literasi finansial.

2.2.2. Comparative Analysis of T5 Model Performance for Indonesian Abstractive Text Summarization (Satya et al., 2025)

Satya et al. (2025) melalui penelitiannya yang berjudul “*Comparative Analysis of T5 Model Performance for Indonesian Abstractive Text Summarization*” melakukan evaluasi performa terhadap berbagai varian model T5 dalam menghasilkan ringkasan abstraktif secara otomatis untuk teks berbahasa Indonesia. Terdapat tiga model yang dibandingkan dalam penelitian tersebut, yaitu T5-Base, FLAN-T5, dan mT5-Base, yang diuji menggunakan dataset INDOSUM yang berisi 19.000 pasangan artikel berita dan ringkasan. Penghitungan skor evaluasi dilakukan secara kuantitatif menggunakan metrik ROUGE(ROUGE-1, ROUGE-2, ROUGE-L) dan juga melalui evaluasi kualitatif guna mengidentifikasi kesalahan peringkasan seperti adanya redundansi, pemotongan teks yang salah, serta inakurasi faktual pada ringkasan yang dihasilkan.

Temuan utama dari penelitian berikut menunjukkan bahwa model FLAN-T5 yang digunakan melalui pendekatan *task instruction tuning* mampu menghasilkan hasil yang terstruktur dalam meringkas teks kompleks serta penuh konteks, dengan perolehan ROUGE-1 model yang mencapai 72%. Model FLAN-T5 juga mampu menghasilkan gaya peringkasan yang kohesif dengan melakukan sedikit pada penyesuaian pada batas token agar tidak terjadi pemotongan teks yang prematur. Pada hasil empiris ditunjukkan bahwa FLAN-T5 memiliki arsitektur yang efektif dalam menangani kompleksitas semantik yang menjadi landasan penting yang mendukung pemilihan model ini dalam penelitian yang diusulkan.

Penelitian Satya et al. (2025) ini relevan terhadap penelitian yang diusulkan melihat dari validasi empirisnya dalam penggunaan varian model T5 untuk tugas peringkasan abstraktif secara terstruktur dan kohesif. Adanya pemotongan token yang membuat hasil pemotongan ringkasan sedikit prematur menjadi pembelajaran penting untuk memperhatikan penyesuaian batas maksimum token pada parameter model saat memproses artikel berita finansial yang berukuran panjang, guna menjaga konteks informasi yang utuh.

Meski terdapat beberapa aspek fundamental yang membedakan sekaligus menunjukkan pembaruan dari penelitian yang diusulkan dibandingkan dengan penelitian yang dilakukan oleh Satya et al. (2025). Pertama, dari segi data penggunaan dataset INDOSUM dalam penelitian Satya et al. berfokus dalam peringkasan teks berbahasa Indonesia dari ranah berita umum yang statis. Sebaliknya, penelitian yang diusulkan akan memproses berita berbahasa Inggris yang difokuskan pada domain aset kripto dengan karakteristik khusus berupa terminologi yang sangat teknis dengan volatilitas arus informasi yang sangat tinggi, sehingga pengaplikasian FLAN-T5 diuji dalam kompleksitas linguistik yang berbeda.

Kedua, dari segi *output*. Penelitian Satya et al. berfokus pada evaluasi ringkasan abstraktif pada format paragraf standar. Sementara itu, penelitian yang diusulkan lebih memaksimalkan metode *instruction fine-tuning* dari FLAN-T5 melalui penerapan *prompt engineering* yang lebih terfokus. Teks berita kripto akan diproses untuk menghasilkan *output* berupa ringkasan yang mampu menghasilkan interpretasi yang padat, objektif, dan konklusif, dalam batasan 1 hingga 2 kalimat. Batasan ini diimplementasikan agar informasi keuangan dapat langsung diserap dengan cepat tanpa kehilangan intisari dari berita itu sendiri.

2.2.3. Multi-label Text Classification for Financial News Using DeBERTa (Timoneda & Vallejo Vera, 2024)

Penelitian yang dilakukan oleh Timoneda dan Vallejo Vera (2024) berjudul "*BERT, RoBERTa or DeBERTa? Comparing Performance Across Transformer Models in Political Science Text*" melakukan evaluasi dan komparasi performa berbagai arsitektur model *Transformer*, yaitu BERT, RoBERTa, dan DeBERTa, pada tugas klasifikasi teks dalam domain yang memiliki bahasa teknis dan ambigu. Meskipun penelitian ini berfokus pada domain teks ilmu politik, implikasinya sangat relevan bagi domain berita keuangan karena keduanya memiliki karakteristik bahasa yang serupa, yaitu terminologi teknis yang kompleks, ambiguitas semantik yang sering muncul, serta struktur kalimat yang kompleks. Penelitian tersebut menggunakan *dataset* berlabel dari berbagai dokumen kebijakan publik dan teks parlemen untuk mengukur akurasi, presisi, *recall*, dan *F1-Score* dari masing-masing model.

Hasil penelitian menunjukkan bahwa DeBERTa secara konsisten mengungguli BERT dan RoBERTa pada hampir seluruh skenario pengujian, terutama pada teks yang mengandung ambiguitas kontekstual tinggi dan terminologi yang bersifat domain-spesifik. Hal ini dikaitkan dengan keunggulan mekanisme *disentangled attention* pada DeBERTa yang mampu memisahkan representasi konten dan posisi kata secara lebih presisi, sehingga menghasilkan pemahaman kontekstual yang lebih mendalam. Penelitian ini juga menyimpulkan bahwa untuk tugas klasifikasi teks pada domain yang membutuhkan pemahaman bahasa yang sangat kontekstual, pemilihan DeBERTa memberikan keunggulan yang signifikan dibandingkan model pendahulunya.

Temuan dari penelitian Timoneda dan Vallejo Vera (2024) memberikan justifikasi empiris yang kuat terhadap pemilihan model DeBERTa-v3 dalam penelitian yang diusulkan untuk tugas klasifikasi multidimensi terhadap berita kripto. Kesamaan karakteristik domain, yaitu bahasa teknis yang penuh dengan terminologi spesifik dan memerlukan pemahaman kontekstual yang mendalam, memperkuat argumen bahwa DeBERTa-v3 merupakan pilihan yang tepat untuk mengklasifikasikan kategori berita, tingkat dampak, target audiens, dan tekanan pasar pada teks berita kripto.

Namun, terdapat beberapa perbedaan mendasar antara kedua penelitian ini. Pertama, penelitian Timoneda dan Vallejo Vera terbatas pada satu tugas klasifikasi tunggal per model (*single-task*), sedangkan penelitian yang diusulkan mengimplementasikan pendekatan klasifikasi multitugas (*multi-task*) menggunakan DeBERTa-v3 yang secara simultan menangani klasifikasi kategori (*single-label*), tingkat dampak/ ordinal, dan identifikasi audiens (*multi-label*). Kedua, penelitian pembandingan tidak mempertimbangkan aspek integrasi sistem atau antarmuka pengguna, sedangkan penelitian yang diusulkan menempatkan model klasifikasi sebagai bagian dari sistem informasi terpadu yang dapat digunakan langsung oleh investor melalui antarmuka web. Ketiga, penelitian Timoneda dan Vallejo Vera tidak mengkombinasikan model klasifikasi dengan model generatif atau model *embedding*, sedangkan penelitian ini mengintegrasikan DeBERTa-v3 bersama FLAN-T5, all-MiniLM-L6-v2, dan

cryptoNER dalam satu pipeline NLP yang saling melengkapi untuk menghasilkan analisis berita yang komprehensif.


	<i>Paper A</i> (Kraaijeveld & De Smedt, 2020)	<i>Paper B</i> (Satya et al., 2025)	<i>Paper C</i> (Timoneda & Vallejo Vera, 2024)	Penelitian yang Diusulkan
Judul	<i>“The Predictive Power of Public Twitter Sentiment for Forecasting Cryptocurrency Prices”</i>	<i>“Comparative Analysis of T5 Model Performance for Indonesian Abstractive Text Summarization”</i>	<i>“BERT, RoBERTa or DeBERTa? Comparing Performance Across Transformer Models in Political Science Text”</i>	<i>"Leveraging NLP Models for Cryptocurrency News Interpretation for Improving Beginner Investor Insights"</i>
Tahun	2020	2025	2024	2025
Model	Lexicon-based, Naive Bayes, Support Vector Machine (SVM)	T5-Base, FLAN-T5, mT5-Base	BERT, RoBERTa, DeBERTa	DeBERTa-v3, FLAN-T5, all-MiniLM-L6-v2, cryptoNER (NER)
Metode	Analisis korelasi sentimen media sosial (Twitter) dengan pergerakan harga kripto	Evaluasi performa peringkasan Abstraktif otomatis pada 19.000 dataset INDOSUM berupa berita umum menggunakan metrik ROUGE secara kuantitatif dan kualitatif.	Evaluasi serta komparasi performa klasifikasi teks dalam domain yang menggunakan bahasa teknis dengan metrik akurasi, presisi, <i>recall</i> , dan <i>F1-Score</i>	Klasifikasi multi-dimensi & <i>multi-task</i> . <i>Abstractive summarization</i> . <i>Novelty detection</i> . NER + <i>entity linking</i> .

Hasil	Menggunakan <i>custom lexicon-based</i> yang digabungkan dengan model VADER mampu memetakan <i>mood</i> terhadap pergerakan pasar kripto, di mana <i>positive tweets</i> dilabeli sebagai <i>buy</i> , <i>neutral</i> sebagai <i>hold</i> , dan <i>negative</i> sebagai <i>sell</i> .	FLAN-T5 mampu menghasilkan ringkasan terstruktur melalui <i>instruction tuing</i> dan mampu mendapatkan skor ROUGE yang cukup tinggi mendekati T5-Base meskipun perlu memperhatikan batasan <i>token</i> untuk menghindari pemotongan teks yang prematur	DeBERTa secara konsisten mengungguli BERT dan RoBERTa pada bahasa teknis berkat adanya <i>disentangled attention</i> yang memisahkan konten dan posisi kata untuk memperjelas pemahaman kontekstual	Pipeline NLP terpadu yang menghasilkan ringkasan, label dampak, <i>novelty score</i> , dan entitas aset terintegrasi.
Analisis Gap & Usulan Kami	Tidak menggunakan sumber berita profesional yang terstruktur, serta tidak menggunakan metode <i>Deep Learning</i> NLP terpadu.	Tidak fokus memaksimalkan <i>prompt engineering</i> pada FLAN-T5 untuk memproses berita kripto.	Tidak mengintegrasikan DeBERTa-v3 dengan model lain dalam pipeline NLP untuk klasifikasi <i>multi-task</i> secara simultan dalam berita kripto.	Mengintegrasikan seluruh <i>gap</i> ketiga paper ke dalam satu platform analitik berbasis web untuk investor pemula.

3. METODE PENELITIAN

Metode Penelitian ini menguraikan secara komprehensif tahapan serta metode yang digunakan dalam merancang, mengimplementasikan, serta mengevaluasi sistem interpretasi berita *cryptocurrency* berbasis *AI*. Pembahasan mencakup kerangka berpikir sistem, teknik pengumpulan data, pemrosesan data, perancangan arsitektur, penyajian *output*, serta skema evaluasi yang digunakan untuk mengukur kerja model dan tingkat *user acceptance*.

3.1. Kerangka Berpikir



Gambar 3.1 Flowchart

Sumber: Dokumentasi Pribadi

Gambar 3.1 menunjukkan kerangka berpikir penelitian yang mengadopsi strategi *Early Exit* untuk efisiensi komputasi. Tahapan dimulai dengan pengambilan data dari CryptoPanic API secara *batching* setiap 15 menit. Data mentah yang masuk melewati tahap *Text Preprocessing* untuk pembersihan komponen non-semantik. Kemudian dilakukan penyaringan berdasarkan relevansi aset (*Filtering Top 10 Crypto*). Sebelum memasuki tahap analisis mendalam, setiap berita dikonversi menjadi vektor 384-dimensi menggunakan all-MiniLM-L6-v2 untuk dilakukan pengecekan kebaruan (*Novelty Detection*) melalui *Cosine Similarity* terhadap basis data PostgreSQL. Berita yang teridentifikasi sebagai *redundant* akan langsung disimpan tanpa proses lebih lanjut. Sebaliknya, berita yang unik akan diteruskan ke tahap inferensi multi-model yang meliputi ekstraksi entitas aset (cryptoNER), multi-klasifikasi (DeBERTa-v3), dan peringkasan naratif (FLAN-T5). Seluruh hasil olahan kemudian disajikan melalui FastAPI untuk divisualisasikan pada *dashboard* berbasis React.js.

3.2. Metode Penelitian

3.2.1. Pengumpulan Data

Pada tahap pengumpulan data, proses *data ingestion* dilakukan secara otomatis menggunakan API dari CryptoPanic yang merupakan *agregator* berita utama. API *aggregator* ini digunakan karena kemampuannya untuk menyatukan berbagai sumber portal berita kripto yang kredibel menjadi satu sumber pintu akses, hal ini menjadikan API *aggregator* efisien untuk digunakan dalam arsitektur sistem. Data mentah yang didapat mencakup *news headline*, *news body* serta *timestamp* yang dikemas dalam format JSON untuk menjamin kompatibilitas aliran data. Mekanisme penarikan data ini dilakukan dalam bentuk *batching* dengan interval waktu setiap 15 menit menggunakan *library* *httpx* dan *APScheduler* dalam Python. Pemilihan proses *batching* setiap 15 menit dilakukan untuk menjaga aktualisasi informasi berita bagi investor dalam rentang *near real-time*.

3.2.2. Pra-pemrosesan Teks (*Text Preprocessing*)

Data yang telah dikumpulkan selanjutnya dimasukkan dalam tahap pra-pemrosesan wajib untuk mengeliminasi *noise* yang dapat menurunkan

tingkat akurasi model. Pra-pemrosesan awal yang dilakukan adalah penghapusan *tag* HTML, karakter khusus, serta simbol non-semantik yang sering terbawa pada tahap penarikan API. Setelah proses *data cleaning* awal selesai, data lanjut ke tahap normalisasi teks untuk menangani kontraksi kata serta penyesuaian pada penulisan huruf. Pendekatan normalisasi data yang digunakan sedikit berbeda, yaitu dengan mempertahankan tanda baca serta huruf kapital. Penggunaan normalisasi yang berbeda ini dilakukan karena *Transformer* (DeBERTa) sangat bergantung pada kelengkapan informasi sintaksis serta kontekstual dari berita aslinya untuk dapat menghasilkan berita representasi semantik berita yang presisi. Data yang sudah dinormalisasikan lalu dimasukkan ke tahap Tokenisasi kontekstual dengan memecah kalimat menjadi unit-unit *sub-word* menggunakan *tokenizer* khusus untuk masing-masing model, seperti DeBERTaTokenizer maupun T5Tokenizer untuk menangani adanya permasalahan *Out-of-Vocabulary* (OOV). Penggunaan *tokenizer* khusus ini dilakukan agar representasi numerik teks terjaga secara semantik sekaligus menjaga retensi informasi penting dari terminologi teknis maupun kosakata baru yang sangat dinamis.

3.2.3. Filter Aset Utama

Pada tahap ini berita memasuki tahap penyaringan aset utama untuk memastikan kriteria dari relevansi data. Seluruh artikel berita akan disaring secara terprogram untuk mengambil berita yang menyebutkan atau berkaitan langsung dengan 10 aset kripto dengan *market capitalization* terbesar per tanggal 17 Mei 2026 (Bitcoin, Ethereum, Tether, BNB, XRP, USDC, Solana, TRON, Dogecoin, Hyperliquid), yang kemudian akan diteruskan ke dalam tahapan analisis *pipeline* NLP berikutnya. Berita yang tidak berkaitan dengan kriteria yang telah disebutkan akan dibuang oleh sistem. Hal ini dilakukan untuk menjaga efisiensi untuk mencegah beban pemrosesan yang mubazir sehingga sumberdaya komputasi dapat dimaksimalkan saat model *Deep Learning* melakukan proses inferensi tingkat lanjut.

3.2.4. Deteksi Kebaruan (*Novelty Detection*)

Pada tahap ini, artikel berita yang telah lolos dari penyaringan aset utama akan dikonversi dalam bentuk representasi matematis. Proses ini

diimplementasikan menggunakan *library* sentence-transformers dengan memuat modul SentenceTransformer untuk menjalankan *pre-trained model* **all-MiniLM-L6-v2**. Model ini bertugas melakukan ekstraksi fitur semantik teks dan menghasilkan keluaran berupa vektor padat (*dense vector*) berdimensi 384 ($d = 384$). Pemilihan model ini didasarkan pada efisiensi performa komputasi yang tinggi, di mana berdasarkan pengujian empiris, proses *encoding* hanya membutuhkan waktu 9 detik untuk 5.000 dokumen sehingga sangat ideal untuk kebutuhan pemrosesan data *near real-time*.

Setelah representasi vektor dari berita baru terbentuk, sistem akan mengukur tingkat kemiripan teks berita tersebut terhadap seluruh data historis artikel yang telah tersimpan di dalam *database*. Proses komparasi ini dihubungkan oleh *back-end* FastAPI menggunakan SQLAlchemy atau *database driver* (psycopg2 / asyncpg) untuk melakukan kueri langsung ke PostgreSQL yang telah dikonfigurasi dengan adanya **pgvector**. Secara matematis, tingkat kesamaan dihitung menggunakan metode **Cosine Similarity** yang mengukur sudut kosinus antara vektor berita baru (A) dan vektor berita historis (B) melalui rumus:
$$\text{Cosine Similarity} = \frac{A \cdot B}{\|A\| \|B\|}$$

Pada level *database*, pencarian kemiripan ini dioptimalkan menggunakan operator jarak kosinus ($\leq$) yang adalah bawaan dari pgvector, di mana nilai skor kesamaan akhir diperoleh dari operasi kalkulasi $1 - (A \leq B)$. Sistem menerapkan *similarity threshold*, yang ditentukan secara konstan sebesar 0.8 sebagai parameter pembuat keputusan. Mekanisme ini bertindak sebagai pemisah alur data (*gatekeeper*) demi menjaga efisiensi komputasi:

- **Jalur Redundan (Early Exit):** Jika skor kemiripan yang dihasilkan > 0.8 , artikel berita tersebut diklasifikasikan sebagai berita yang bersifat repetitif atau redundan. Sistem akan menetapkan nilai *Boolean* `is_redundant = TRUE` dan memberikan label tingkat kebaruan `novelty_label = 'Low'`. Data ini akan langsung disimpan secara permanen ke PostgreSQL tanpa dilewatkan ke pemrosesan model AI yang membutuhkan beban komputasi tinggi.

- **Jalur Unik (*Full Pipeline*):** Jika skor kemiripan yang dihasilkan ≤ 0.8 , artikel berita tersebut dinyatakan sebagai berita baru atau unik. Sistem akan menetapkan nilai Boolean `is_redundant = FALSE` dan mengizinkan aliran data teks untuk diteruskan ke dalam *pipeline AI*.

3.2.5. Implementasi Inferensi AI (Analisis Mendalam)

Tahap ini menjelaskan bagaimana artikel berita yang berstatus unik (`is_redundant = FALSE`) diolah untuk menghasilkan analisis semantik yang komprehensif. Agar proses inferensi tidak memakan waktu lama, *back-end* FastAPI mengelola pemrosesan tiga arsitektur model NLP utama secara asinkron menggunakan modul bawaan Python yaitu `asyncio`, secara spesifik lewat *function* `asyncio.gather()`. Pendekatan ini memungkinkan model menjalankan tugasnya masing-masing secara *parallel* tanpa saling memblokir, sehingga mengoptimalkan utilitas sumber daya komputasi *hardware*.

Proses ekstraksi entitas koin diimplementasikan dengan memuat kelas *AutoModelForTokenClassification* dan *AutoTokenizer* dari *library* Hugging Face *transformers* untuk memanggil model **covalenthq/cryptoNER**. Model berbasis arsitektur *pre-trained* XLM-RoBERTa-base ini mengekstraksi kata kunci pada *token classification* dengan memanfaatkan mekanisme *dynamic masking* yang adaptif terhadap domain aset kripto. Setelah simbol entitas koin (seperti BTC atau ETH) berhasil diekstrak dengan akurasi tinggi (berdasarkan parameter teknis *F1-Score*), data tersebut diteruskan ke modul internal berbasis *Dictionary-based Entity Linking*. Modul ini mencocokkan teks entitas dengan kamus aset di dalam sistem untuk memetakan hasil ekstraksi secara tepat ke ID unik aset di *database* agar menghindari ambiguitas simbol.

Proses klasifikasi teks dalam penelitian ini dirancang menggunakan pendekatan **Multi-Task Learning (MTL)** memanfaatkan model **DeBERTa-v3** (`microsoft/deberta-v3-base`) yang berjalan di atas *library* *transformers* dan dikombinasikan menggunakan modul `torch.nn` (PyTorch). Melalui mekanisme *disentangled attention*, model mengekstrak representasi vektor dari teks berita utuh (*news body*) dengan memisahkan matriks konten dan posisi secara presisi.

Untuk menghemat waktu inferensi pada lingkungan *near real-time*, sistem tidak menggunakan empat model terpisah, melainkan memasang empat buah lapisan klasifikasi (*Classification Heads/Linear Layers*) secara paralel di atas arsitektur *Transformer* yang sama. Pendekatan ini memungkinkan sistem hanya melakukan satu kali putaran komputasi (*single forward pass*) untuk menghasilkan empat dimensi analisis yang spesifik secara bersamaan dengan detail mekanis sebagai berikut.

- **Kategori Berita** (*Multi-class Single-label Classification*): Lapisan *linear layer* memetakan vektor *hidden state* dari token khusus [CLS] menuju ke sejumlah neuron sesuai total kategori berita (*Price Movement, Regulation, Security, Adoption*). Hasil *logits* diproses menggunakan fungsi aktivasi **Softmax** untuk menghasilkan distribusi probabilitas, di mana label dengan nilai tertinggi dipilih sebagai *output* mutlak.
- **Tingkat Dampak Berita** (*Ordinal Classification*): Lapisan ini bertugas mengukur bobot urgensi berita ke dalam tingkatan bergradasi, yaitu *Low, Medium*, atau *High Impact*. Karena kelas memiliki urutan tingkatan bobot, lapisan *linear* memproyeksikan skor skala yang kemudian dinormalisasi menggunakan fungsi **Softmax** untuk mengunci posisi dampak berita terhadap pasar secara berurutan.
- **Target Investor** (*Multi-label Classification*): Lapisan ini bertugas mengidentifikasi kelompok investor mana saja yang terdampak oleh isi berita (*Day Traders, Long-term Holders, Whales*). Karena satu berita bisa berdampak pada lebih dari satu kelompok sekaligus, lapisan *linear* ini menggunakan fungsi aktivasi **Sigmoid** secara independen pada setiap neuron *output*. Sistem menerapkan parameter *threshold* konstan ≥ 0.5 , setiap kelompok investor yang memiliki skor probabilitas di atas nilai ambang batas tersebut akan otomatis ditetapkan sebagai label *output*.
- **Tekanan Arah Pasar** (*Multi-class Single-label Classification*): Lapisan klasifikasi akhir ini bertugas memprediksi sentimen dampak psikologis berita terhadap arah pergerakan pasar. Nilai *output* dipetakan ke dalam tiga kelas independen (*Bullish, Bearish, Neutral*)

menggunakan fungsi aktivasi **Softmax** untuk mengambil satu keputusan sentimen yang paling dominan dari teks berita kripto tersebut.

Model generatif **FLAN-T5** diimplementasikan dengan memuat kelas *AutoModelForSeq2SeqLM* berbasis arsitektur *encoder-decoder text-to-text*. Model ini dioptimalkan menggunakan mekanisme *relative position bias* serta teknik *instruction fine-tuning*. Dalam melakukan peringkasan, teks berita diolah melalui modul *prompt engineering* menggunakan parameter generasi teks seperti `max_new_tokens=50`, `temperature=0.7`, dan `top_p=0.9` untuk mengontrol tingkat kepadatan kalimat. Model ini mensintesis keseluruhan informasi teks berita yang kompleks menjadi 1–2 kalimat penjelasan interpretasi naratif yang objektif dan koheren.

Setelah ketiga proses inferensi paralel selesai, sistem akan memasuki tahap agregasi data di dalam memori *backend*. FastAPI menggunakan *class* skema data (seperti *Pydantic*) untuk menangkap dan menyatukan seluruh *output* yang terpisah, yaitu *array* ID entitas koin dari *cryptoNER*, 4 buah label teks dari *DeBERTa-v3*, dan *string* teks ringkasan dari *FLAN-T5*. Pada tahap ini juga, sistem memberikan penanda akhir nilai tingkat kebaruan berita (*novelty label*) sebagai status "High" atau "Low" berdasarkan sisa skor jarak hasil *Cosine Similarity* yang didapat sebelumnya. Seluruh variabel komponen analisis ini digabungkan bersama struktur *metadata* awal berita menjadi satu objek *data record* JSON yang utuh dan siap dikirim ke fungsi penyimpanan *database*.

3.2.6. Penyimpanan Data dan Penyajian API (*Data Serving & Backend*)

Setelah selesai melakukan proses analisis, data hasil inferensi yang mencakup hasil klasifikasi, ringkasan naratif, ekstraksi entitas, dan penentuan korelevanan berita (*novelty level*) akan disimpan secara permanen ke pusat data PostgreSQL. Proses pengelolaan data tersebut dilakukan oleh sistem *back-end* berbasis FastAPI yang bertugas sebagai pusat melakukan logika bisnis (*business logic*) sistem. FastAPI juga bertanggung jawab untuk menyediakan layanan REST API berupa respon objek JSON yang akan digunakan oleh *front-end*. FastAPI digunakan karena memungkinkan proses penyajian data dan inferensi model yang berjalan dalam latensi rendah, performa yang optimal, dan efisien,

terutama cocok untuk sistem berbasis *Artificial Intelligence* yang butuh proses komputasi secara *real-time*.

3.2.7. Visualisasi Antarmuka

Sisi *front-end* sistem dikembangkan menggunakan *framework* React.js, karena memiliki kelebihan dalam arsitektur berbasis komponen (*component-based architecture*) dan mekanisme *Virtual DOM* yang ringan dan efisien. React.js digunakan untuk membangun sistem antarmuka *dashboard* yang responsif dan dinamis bagi pengguna. *Framework* ini digunakan dengan cara melakukan pengambilan data (*fetch request*), terhadap REST API yang disediakan oleh FastAPI untuk memperoleh hasil analisis berita kripto secara *real-time*.

Antarmuka utama aplikasi menampilkan 10 aset kripto dengan *market capitalization* terbesar yang telah ditentukan. Masing-masing aset kripto memiliki halaman *detail* yang menampilkan kumpulan berita yang terkait. Kemudian setiap berita yang ditampilkan tersebut dapat dipilih, untuk menampilkan halaman yang menampilkan hasil analisis model secara lebih mendalam.

Data yang diterima akan divisualisasikan dalam berbagai komponen antarmuka, seperti ringkasan berita secara naratif, kategori berita, indikator warna otomatis berdasarkan dampak pasar, label kebaruan berita, hingga visualisasi tren tekanan pasar. Penyajian informasi berita secara visual tersebut ditujukan untuk membantu investor pemula untuk memahami kondisi pasar kripto secara lebih cepat, sederhana, dan intuitif.

3.2.8. Evaluasi


Evaluasi dilakukan untuk mengukur performa teknis model *Artificial Intelligence* yang digunakan, dan menilai kualitas sistem dari sisi pengguna. Evaluasi secara teknis dilakukan terhadap model DeBERTa-v3 dan cryptoNER menggunakan metrik kuantitatif seperti *Accuracy*, *Precision*, *Recall*, dan *F1-score*. Selain itu, visualisasi Confusion Matrix juga akan digunakan untuk menganalisis pola kesalahan prediksi yang didapatkan dari model klasifikasi. Selain itu, kualitas hasil ringkasan abstraktif dari model FLAN-T5 dievaluasi

menggunakan metrik ROUGE-1, ROUGE-2, dan ROUGE-L untuk mengukur *lexical similarities* antara hasil generasi model dengan referensi ringkasan. Pengukuran kesamaan semantik secara lebih mendalam akan menggunakan metrik BERTScore yang dapat mengevaluasi kedekatan makna antar-teks.

Selain evaluasi model secara teknis, dilakukan pula evaluasi pengalaman pengguna (*User Acceptance Testing*). Pengujian fungsionalitas dan kualitas antarmuka web akan dilakukan dengan metode *System Usability Scale* (SUS), untuk mendapatkan tingkat penerimaan sistem dari sisi pengguna. Selanjutnya, penelitian juga mengukur dampak penggunaan sistem terhadap perilaku dan literasi finansial pengguna dengan metode *pre-test* dan *post-test*. Pengukuran dilakukan menggunakan kuesioner skala literasi dan FOMO untuk mengetahui apakah sistem berhasil membantu pengguna dalam mengurangi perilaku investasi yang emosional dan impulsif. Data tersebut kemudian akan diproses menggunakan metode statistik *Paired Sample T-Test* untuk menguji signifikansi perubahan sebelum dan sesudah menggunakan sistem ini.

3.3. Perancangan Sistem


3.3.1. Data Flow / Context Diagram (Level 0)



Gambar 3.3.1 Data Flow Diagram Level 0

Data Flow Diagram pada Gambar 3.3.1 menunjukkan *Context Diagram* yang menggambarkan sistem secara keseluruhan. Diagram ini digambarkan tanpa merinci sub-proses maupun penyimpanan data internal di dalamnya. Diagram ini fokus kepada identifikasi batas sistem dan hubungannya terhadap kedua entitas eksternal. Entitas pertama yakni *CryptoPanic API* berperan sebagai sumber data eksternal yang mengalirkan data mentah (*raw news JSON*) ke dalam sistem. Entitas *Users* berinteraksi dalam dua arah dengan sistem. Di satu sisi, mereka menerima keluaran berupa antarmuka yang ditampilkan, disisi lain mereka mengirimkan input yaitu *coinID* dan *newsID* sebagai permintaan data secara spesifik kepada sistem. *Context Diagram* ini berfungsi sebagai acuan tingkat tinggi yang menunjukkan ruang lingkup sistem secara keseluruhan.

3.3.2. Data Flow Diagram (Level 1)



Gambar 3.3.2 Data Flow Diagram


Data Flow Diagram pada gambar 3.3.2 memetakan aliran informasi sistem secara logis, mulai dari tahapan pertama yang dilakukan yaitu pengumpulan data mentah hingga tahap akhir penyajian interpretasi berita mata uang kripto. Interaksi dalam sistem ini berhubungan dengan dua entitas eksternal utama yaitu CryptoPanic API sebagai penyedia data berita mentah dalam format JSON, dan pengguna sebagai penerima akhir dalam bentuk *Rendered UI* yang sudah diproses.

Pada tahapan awal transformasi data pada Proses 1.0 (*Ingestion & Preprocessing*) data JSON dari API diurai. Data artikel yang telah dipilah disimpan ke dalam *Store Raw Article*, dan teks yang sudah dibersihkan akan dilanjutkan menuju Proses 2.0 (*Novelty Detection*), dalam tahapan ini tingkat kebaruan informasi teks dievaluasi. Proses ini menghasilkan representasi vektor 384 dimensi yang kemudian akan disimpan dalam *pgvector Store*. Informasi berita yang dinilai redundan oleh sistem, aliran data tersebut akan dialihkan ke dalam penyampaian berita duplikat yaitu *Store Redundant News*. Artikel-artikel yang dinilai unik akan diteruskan ke tahap pemrosesan NLP tingkat lanjut.

Artikel unik yang masuk ke tahap pemrosesan NLP yang memiliki 3 proses. Proses 3.0 (*NER Extraction*) akan menggunakan model cryptoNER akan mengekstraksi identitas spesifik yang berkaitan mata uang kripto, sehingga menghasilkan aliran data *Extracted Entities*. Pada Proses 4.0 (*Multi-Classification*) model DeBERTa-v3 digunakan untuk mengklasifikasikan kategori atau sentimen berita untuk mendapatkan aliran data *Classified Labels*. Pada Proses 5.0 (*Summarization*) pemrosesan NLP ini menggunakan model FLAN-T5 yang berfungsi untuk merangkum konten berita menjadi aliran data *Text Summary*. Dari ketiga pemrosesan NLP tersebut seluruh keluarannya akan dikonsolidasikan pada Proses 6.0 (*Result Aggregation*). Dalam proses ini entitas terekstraksi, label terklasifikasi, dan ringkasan teks akan disatukan untuk membentuk *Structured Record* yang kemudian akan disimpan secara permanen dalam *Store Result*. Selanjutnya proses agregasi akan menyalurkan *Novelty Labels Assigned* yang sudah disematkan ke tahapan terakhir yaitu Proses 7.0 (*API Serving & UI Rendering*).

Proses terakhir ini bertugas memformat data yang telah diinterpretasikan secara komprehensif menjadi antarmuka pengguna yang *ter-render*. Pada tahap ini terdapat dua aliran data yang saling melengkapi: pertama, entitas *Users* mengirimkan *Selected coinID* atau *newsID* sebagai permintaan spesifik ke sistem, dan kedua, *Store Results* menyalurkan kembali *Requested Coin/News Details* ke Proses 7.0 untuk memenuhi permintaan tersebut. Hasil akhir dari proses inilah yang disajikan kepada entitas *Users* sebagai *Rendered UI*. Dalam rangkaian aliran data ini, informasi yang diterima pengguna dipastikan telah melalui proses seleksi, analisis komputasi NLP, dan agregasi untuk menghindari adanya redundansi pemrosesan.

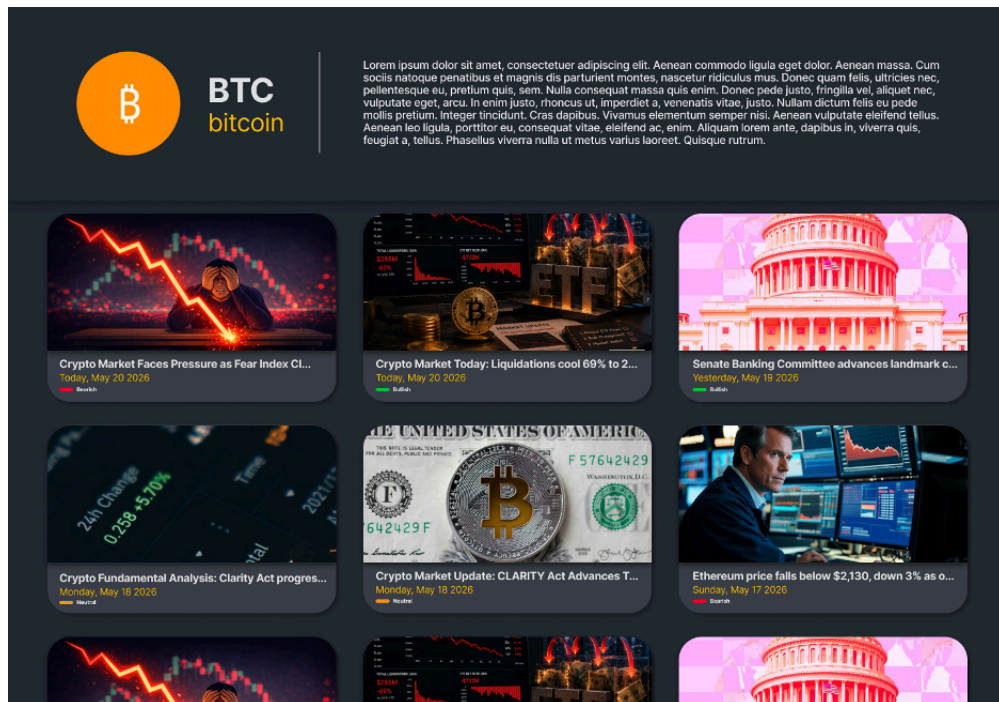
3.3.3. User Interface Design



Gambar 3.3.3 Dashboard Top 10 Assets Page


Tampilan pada gambar 3.3.3 merupakan halaman utama (*dashboard*) aplikasi CryptoNews dalam tab “*Top 10 Assets*”. Halaman ini menyajikan daftar 10 aset kripto teratas yang sudah *hard-coded* berdasarkan jumlah market cap pada periode penelitian. Setiap *card* menampilkan identitas aset seperti simbol, nama unik koin, nama lengkap koin, serta jumlah berita unik yang berhasil diproses sistem pada hari tersebut. *Card* yang tidak memiliki berita relevan pada hari tersebut ditandai sebagai “*No news today*”. Sedangkan *card* yang memiliki berita aktif pada hari tersebut akan menampilkan jumlah berita yang sudah

berhasil diproses dengan *pipeline NLP model*. Halaman ini berfungsi sebagai titik navigasi utama yang menghubungkan pengguna ke halaman detail per aset.



Gambar 3.3.4 Coin Detail Page

Gambar 3.3.4 menunjukkan halaman detail per aset kripto yang dapat diakses ketika pengguna memilih salah satu koin dari halaman *Top 10 assets*. Bagian *header* halaman menampilkan identitas aset berupa simbol, nama unik koin, nama lengkap koin, beserta teks deskripsi singkat mengenai aset tersebut untuk memberikan konteks dasar ke investor pemula. Bagian isi dibawah *header* menampilkan daftar berita yang secara spesifik berkaitan dengan aset kripto tersebut dalam format *grid*, lengkap dengan *thumbnail*, judul berita, tanggal publikasi, dan label sentimen per berita. Koneksi antara berita dengan aset secara spesifik dimungkinkan oleh output model *cryptoNER* yang secara otomatis mengidentifikasi dan menghubungkan entitas aset kripto yang disebutkan dalam sebuah berita.



Gambar 3.3.5 Dashboard Latest News Page

Gambar 3.3.5 menampilkan halaman utama aplikasi CryptoNews pada tab “*Latest News*”. Halaman ini menyajikan daftar berita kripto terkini yang ditarik dari CryptoPanic API setiap 15 menit dalam format *grid* tiga kolom. Setiap *card* berita menampilkan *thumbnail*, judul berita yang dipersingkat, tanggal dan waktu publikasi, dan label sentimen yang dihasilkan oleh model DeBERTa-v3 (dikategorikan sebagai *Bullish*, *Neutral*, dan, *Bearish*). Tampilan ini dirancang untuk memberikan akses secara cepat kepada investor pemula terhadap berita kripto terbaru, beserta interpretasi sentimen awal. Sehingga pengguna dapat langsung mendapatkan gambaran bagaimana berita tersebut secara spesifik menandai arah pergerakan pasar tanpa perlu membaca isi artikel secara menyeluruh terlebih dahulu.



Gambar 3.3.6 News Page

Gambar 3.3.6 menampilkan detail berita yang muncul ketika pengguna memilih salah satu berita dari halaman *Latest News*. Halaman ini menyajikan gambar *header* berita, lengkap dengan judul lengkap artikel, *timestamp* publikasi dalam format UTC, dan label sentimen yang telah dihasilkan oleh model DeBERTa-v3. Bagian utama halaman menampilkan konten berita yang sudah diringkas secara otomatis oleh model FLAN-T5, menggantikan teks asli yang panjang dan teknis dengan teks yang lebih mudah dimengerti oleh pengguna. Halaman ini adalah komponen inti dari sistem yang secara langsung menjawab permasalahan *information overload*, dengan menyederhanakan berita kripto yang kompleks menjadi konten yang mudah untuk dikonsumsi tanpa memerlukan literasi finansial yang tinggi.

DAFTAR PUSTAKA

1. Kraaijeveld, O., & De Smedt, T. (2020). The predictive power of public Twitter sentiment for forecasting cryptocurrency prices. *Journal of International Financial Markets, Institutions and Money*, 65, 101188.
<https://doi.org/10.1016/j.intfin.2020.101188>
2. Corbet, S., Hou, Y., Hu, Y., Larkin, C., & Oxley, L. (2020). Any port in a storm: Cryptocurrency safe-havens during the COVID-19 pandemic. *Economics Letters*, 194, 109377.
<https://doi.org/10.1016/j.econlet.2020.109377>
3. Li, Q., & Wang, R. (2020). Impact of major cryptocurrency events on market volatility. *IEEE Access*, 8, 121497–121509.
<https://doi.org/10.1109/ACCESS.2020.3006354>
4. Merva, E., Stanford, M., & Lewis, C. (2022). Cryptocurrency literacy and investor risk perception. *Financial Innovation*, 8(1), 1–18.
<https://doi.org/10.1186/s40854-022-00345-6>
5. Chainalysis. (2023). *The 2023 global crypto adoption index*.
<https://www.chainalysis.com>
6. Otoritas Jasa Keuangan. (2022). *Strategi nasional literasi keuangan digital Indonesia*.
<https://www.ojk.go.id>
7. Narayanan, A., Bonneau, J., Felten, E., Miller, A., & Goldfeder, S. (2016). *Bitcoin and cryptocurrency technologies: A comprehensive introduction*. Princeton University Press.
8. Song, Zhizhuo. (2025). Behavioral Biases in the Cryptocurrency Market: A Study on the Impact of Investor Sentiment on Price Anomalies. *Journal of Applied Economics and Policy Studies*. 18. 36-40. 10.54254/2977-5701/2025.21938.
9. Kaushal, A., & Chauhan, R. (2025, June). Hyperparameter Tuning for Domain-Specific Text Generation: A Case Study with FLAN-T5. In *2025 3rd International Conference on Inventive Computing and Informatics (ICICI)* (pp. 01-06). IEEE.
10. Yin, C., & Zhang, Z. (2024, October). A study of sentence similarity based on the all-minilm-l6-v2 model with “same semantics, different structure” after fine tuning. In

11. Shelar, H., Kaur, G., Heda, N., & Agrawal, P. (2020). Named entity recognition approaches and their comparison for custom ner model. *Science & Technology Libraries*, 39(3), 324-337.
12. He, P., Gao, J., & Chen, Wx. (2021). *DeBERTaV3: Improving DeBERTa using ELECTRA-style pre-training with gradient-disentangled embedding sharing*. arXiv.
13. Wei, J., Bosma, M., Zhao, V. Y., et al. (2021). *Finetuned language models are zero-shot learners*. arXiv.
14. Putri, A. E. S., & Purnomo, A. S. D. (2025). *Pengaruh FoMO dan financial influencer di media sosial terhadap keputusan investasi cryptocurrency generasi Z dengan literasi kripto sebagai variabel moderasi*. *Jurnal Manajemen Pendidikan*, 10(4), 2338–2351.
15. Aritonang, D. E., & Hariwibowo, I. N. (2024). *Fenomena “FoMO” investasi cryptocurrency: Analisis sentimen*. *Konstelasi: Konvergensi Teknologi dan Sistem Informasi*, 4(2).
16. Söylemez, M., Tekinerdogan, B., & Kolukısa Tarhan, A. (2022). Challenges and solution directions of microservice architectures: A systematic literature review. *Applied Sciences*, 12 (11), 5507. <https://doi.org/10.3390/app12115507>
17. Mokoginta, J., et al. (2024). Comparative analysis of modern JavaScript frameworks (React, Angular, Vue) for web development. *International Journal of Software Engineering and Computer Science*.
<https://journal.lembagakita.org/index.php/ijsecs/article/view/2831>
18. Colangelo, M. T., Meleti, M., Guizzardi, S., Calciolari, E., & Galli, C. (2025). *A comparative analysis of sentence transformer models for automated journal recommendation using PubMed metadata*. *Big Data and Cognitive Computing*, 9(3), 67. <https://doi.org/10.3390/bdcc9030067>
19. Satya, M. W. B. D., Luthfiarta, A., & Althoff, M. N. (2025). *Comparative analysis of T5 model performance for Indonesian abstractive text summarization*. *Sistemasi: Jurnal Sistem Informasi*, 14(3), 1092–1106.
20. He, P., Liu, X., Gao, J., & Chen, W. (2019). *DeBERTa: Decoding-enhanced BERT with disentangled attention*. arXiv preprint arXiv:2006.03654.
<https://arxiv.org/abs/2006.03654>

21. Gharehchopogh, F. S., & Abdollahzadeh, B. (2021). *A Comprehensive Survey on Deep Learning in Big Data Analytics: Models, platforms, and challenges*. Journal of Network and Computer Applications, 186, 103125.
22. Vuppalapati, C. (2021). *Building real-time data pipelines: Unlocking data in motion*. O'Reilly Media.
23. Hugging Face. (2024). *Model Card: Covalenthq/cryptoNER*. Hugging Face Open Source Models. <https://huggingface.co/covalenthq/cryptoNER>
24. C. Timoneda, Joan & Vallejo Vera, Sebastián. (2024). *BERT, RoBERTa or DeBERTa? Comparing Performance Across Transformers Models in Political Science Text*. The Journal of Politics. 87. 10.1086/730737. <https://www.journals.uchicago.edu/doi/10.1086/730737>
25. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. Advances in neural information processing systems, 30. <https://arxiv.org/abs/1706.03762>
26. Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., ... & Liu, P. J. (2020). Exploring the limits of transfer learning with a unified text-to-text transformer. Journal of Machine Learning Research, 21 (140), 1–67. <https://arxiv.org/abs/1910.10683>
27. Lewis, James. (2018). The System Usability Scale: Past, Present, and Future. International Journal of Human-Computer Interaction. 1-14. 10.1080/10447318.2018.1455307. https://www.researchgate.net/publication/324116412_The_System_Usability_Scale_Past_Present_and_Future
28. Seifermann, S., Heinrich, R., Werle, D., & Reussner, R. (2022). Detecting violations of access control and information flow policies in data flow diagrams. *Journal of Systems and Software*, 184, 111138. <https://doi.org/10.1016/j.jss.2021.111138>
29. Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). Bertscore: Evaluating text generation with bert. arXiv preprint arXiv:1904.09675. <https://arxiv.org/abs/1904.09675>

30. Ivantchev, B., & Ivantcheva, M. (2024). FOMO effect: Social media and online traders. *Journal of Management and Financial Sciences*.
<https://econjournals.sgh.waw.pl/JMFS/article/view/4263>
31. Klepacki, J. (2025). The Fear of Missing Out (FOMO) effect in cryptocurrency trading. *European Research Studies Journal*, 28(2), 938–949.
<https://doi.org/10.35808/ersj/4019>
32. Li, Y., Delfabbro, P., & King, D. (2025). Investigating the role of regret, FOMO and financial literacy in cryptocurrency speculation. *International Journal of Mental Health and Addiction*.
<https://doi.org/10.1007/s11469-025-01555-6>
33. Otoritas Jasa Keuangan. (2022). *Survei nasional literasi keuangan digital Indonesia*.
<https://ojk.go.id/id/berita-dan-kegiatan/siaran-pers/Pages/Survei-Nasional-Literasi-da-n-Inklusi-Keuangan-Tahun-2022.aspx>
34. Putri, A. E. S., & Purnomo, A. S. D. (2025). Pengaruh FoMO dan financial influencer di media sosial terhadap keputusan investasi cryptocurrency generasi Z.
<https://ejurnal.stkip-pessel.ac.id/index.php/jmp/article/view/1144>
35. He, P., Liu, X., Gao, J., & Chen, W. (2021). DeBERTa: Decoding-enhanced BERT with disentangled attention. *International Conference on Learning Representations (ICLR)*.
<https://arxiv.org/abs/2006.03654>
36. Jurafsky, D., & Martin, J. H. (2024). Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition. Stanford University.
https://web.stanford.edu/~jurafsky/slp3/ed3book_jan26.pdf
37. Li, J., Sun, A., Han, J., & Li, C. (2020). A survey on deep learning for named entity recognition. *IEEE transactions on knowledge and data engineering*, 34(1), 50-70.
<https://arxiv.org/pdf/1812.09449>
38. Bender, E. M., & Koller, A. (2020, July). Climbing towards NLU: On meaning, form, and understanding in the age of data. In *Proceedings of the 58th annual meeting of the*

association for computational linguistics (pp. 5185-5198).

<https://aclanthology.org/2020.acl-main.463.pdf>

39. Khan, S., Naseer, M., Hayat, M., Zamir, S. W., Khan, F. S., & Shah, M. (2022).

Transformers in vision: A survey. *ACM Computing Surveys*.

<https://dl.acm.org/doi/full/10.1145/3505244>

40. Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., ... & Rush, A. M.

(2020, October). Transformers: State-of-the-art natural language processing. In

Proceedings of the 2020 conference on empirical methods in natural language

processing: system demonstrations (pp. 38-45). <https://arxiv.org/pdf/1910.03771>

41. Chung, H. W., Hou, L., Longpre, S., Zoph, B., Tay, Y., Fedus, W., ... & Wei, J. (2024).

Scaling instruction-finetuned language models. *Journal of Machine Learning*

Research, 25(70), 1-53. <https://arxiv.org/pdf/2210.11416>

42. Li, Y., Wang, S., Ding, H., & Chen, H. (2023, November). Large language models in

finance: A survey. In Proceedings of the fourth ACM international conference on AI

in finance (pp. 374-382). <https://arxiv.org/pdf/2311.10723>

Sumber gambar:

1. Abraha, T., & Nazir, A. (2024). Evaluation of transformer-based neural language models for writing feedback and automated essay scoring. https://www.researchgate.net/figure/A-High-Level-Overview-of-the-DeBERTa-Models-Architecture_fig2_378752229
2. Putra, C., Arlis, S., & Nurcahyo, G. W. (2025). Large Language Model Method as a Translator Indonesian Into SQL Language. *Jurnal KomtekInfo*, 124-130. https://www.researchgate.net/figure/Architectural-Diagram-of-FLAN-T5_fig1_396492336